

学校代码: 10699

分类号:

学号: 2024264208

密级: 公开

# 西北工业大学

## 硕士学位论文

(专业学位)

面向军事情报问答的  
检索增强生成方法研究

作者: 舒适

专业领域: 软件工程

指导教师: 汪彦婷 讲师

校外导师: 马城城 高级工程师

培养单位: 软件学院

申请日期: 2027 年 3 月

西北工业大学

硕士学位论文

(专业学位)

题目：面向军事情报问答的  
检索增强生成方法研究

专业领域： 软件工程

作者： 舒 适

指导教师： 汪彦婷 讲师

校外导师： 马城城 高级工程师

2027 年 3 月

## 学位论文使用授权声明

本人完全了解学校有关保护知识产权的规定，即：研究生在校攻读学位期间论文工作的知识产权属于西北工业大学。学校有权保留并向国家有关部门或机构送交论文的复印件和电子版。本人允许论文被查阅和借阅，学校可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。同时本人保证，毕业后结合学位论文研究课题再撰写的文章一律署名单位为西北工业大学。

## 摘要

现代战场情报的数据量近年来增长很快，来源也比较杂，单纯依靠人工分析往往难以满足时效需求。以大语言模型为核心的问答技术为情报分析提供了一条可能的辅助路径，但大语言模型存在知识滞后、专业知识不足、容易产生幻觉等问题，难以直接用于对精度和可信度要求较高的军事情报场景。检索增强生成 (Retrieval-Augmented Generation, RAG) 通过在生成前引入外部知识库检索，是缓解上述问题的常见思路。不过现有 RAG 方法用到军事情报场景时还有几个比较突出的问题：一是缺少面向军事问答的领域数据集，通用嵌入模型对军事术语的匹配能力有限；二是一次性检索难以覆盖装备、部署、地形、行动等多方面联动的多跳推理问题；三是检索库中可能混入噪声甚至敌方植入的对抗文本，而现有方法缺少相应的可信度判断与过滤手段。

针对这些问题，本文围绕军事情报问答的 RAG 方法做了一些改进，主要工作如下。需要说明的是，本文方法依赖对开源大模型内部状态 (token 概率、注意力等) 的访问，仅适用于可白盒部署的开源模型，不适用于闭源 API 模型。

(1) 构建了面向军事情报问答的领域知识库与对抗评测数据集。基于 CMNEE 军事新闻事件抽取数据集、公开军事条令与防务评论等多源数据，设计了包含文本清洗、实体识别、情报分块、向量化索引的多阶段预处理流程，构建分类组织的军事情报知识库。在此基础上，按照“事实核验—关联分析—推理判断—综合生成”的能力链条，构造了包含基础事实验证、复杂战术推理、对抗误导样本三类、总规模 1276 条的军事情报问答数据集，并采用“机器初标 + 人工校验”的双阶段流程保障质量。用这批数据对 BGE 嵌入模型做 LoRA 微调后，军事检索任务上的 Recall@10 从 71.4% 提升到约 78.6%；受限于数据规模，提升幅度有限，且对不同类型查询改善不均衡。

(2) 在 FLARE 等单信号触发方法基础上，改进了动态检索的触发与查询重构。生成过程中监测 Token 概率、注意力权重、输出熵三个信号，加权后判断是否需要补检索；针对不同问题类型尝试了实体增强、实词聚焦、上下文融合三种查询重构方式，并设计了多轮检索的终止条件。在复杂推理子集上 F1 从 50.3% 提升到约 61.5%，但这一改进以增加推理延迟为代价，且在简单事实问题上收益有限。

(3) 针对检索库可能被污染的情况，设计了一种两阶段的过滤与可信判断方法。前置阶段用语义聚类配合领域特征过滤可疑文档；后置阶段从模型取出内部先验，与外部证据做一致性比对来识别冲突，并用证据覆盖度、对齐度、自一致性、不确定性四个指标判断回答是否可信，必要时拒答或补检索。在 10% 投毒率下该方法把攻击成功率从朴素 RAG 的 47.5% 降到约 32.5%；但它无法完全消除投毒影响，高投毒率下效果明显变差，且过滤阶段存在误删正确文档、导致召回略降的情况。

(4) 把上述模块组织成一个可本地离线运行的问答系统原型，按数据层、控制层、安全防御层划分，并从问答准确性、复杂推理、鲁棒性、可信度、效率几个方面做了评估。本文工作可为军事情报问答系统的构建提供一些方法上的参考，但仍属于硕士阶段的改进性工作，距离实战部署还有不少需要完善的地方。

**关键词：**检索增强生成；军事情报问答；大语言模型；动态检索；对抗鲁棒性

# Abstract

With the continuous evolution of systematic and clustered combat paradigms, the volume and generation speed of modern battlefield intelligence have grown exponentially, rendering manual analysis insufficient to meet the rapidly changing demands of decision-making. Question answering technology powered by Large Language Models (LLMs) offers a promising approach for intelligence analysis and decision support. However, LLMs suffer from intrinsic limitations such as knowledge cutoff, lack of domain expertise, and hallucination, which prevent their direct application to military intelligence scenarios that demand strict accuracy and trustworthiness. Retrieval-Augmented Generation (RAG), which combines LLMs with authoritative external knowledge bases, has been considered a key technology to mitigate these problems. Nevertheless, existing RAG methods still face three challenges in the military intelligence domain: (1) a lack of high-quality domain-specific datasets and inadequate semantic matching of general embeddings for military terminology; (2) the conventional one-shot retrieval paradigm cannot handle complex multi-hop reasoning that links equipment, deployment, terrain, and action; (3) the adversarial nature of military intelligence corpora, where existing RAG lacks effective trustworthiness assessment and noise filtering mechanisms.

To address these issues, this thesis investigates retrieval-augmented generation methods for military intelligence question answering along three main lines—domain adaptation, dynamic reasoning, and adversarial robustness. The main contributions are summarized as follows.

(1) A military intelligence knowledge base and adversarial evaluation dataset are constructed. A multi-stage preprocessing pipeline is designed for multi-source corpora including CMNEE, declassified military doctrines, and defense commentaries. A military QA dataset of 1,276 samples is built and validated through a machine-annotation-plus-human-verification workflow. The BGE embedding model is fine-tuned via LoRA, improving Recall@10 from 71.4% to about 78.6% on military retrieval, though the gain is limited by the dataset size.

(2) A dynamic retrieval and adaptive query reformulation mechanism driven by real-time information need is proposed. By monitoring token-level probability, attention weights, and output entropy during generation, a task-adaptive fusion function precisely detects knowledge gaps. Three reformulation strategies—entity enhancement, content-word focusing, and context fusion—are designed and automatically selected. A closed-loop reasoning procedure with explicit termination criteria improves F1 from 50.3% to about 61.5% on the complex reasoning subset, at the cost of higher latency.

(3) A two-stage trustworthy enhancement and noise filtering mechanism for adversarial environments is proposed. A pre-stage semantic clustering filter combined with domain feature enhancement identifies and removes suspicious documents; a post-stage consistency-conflict detector extracts internal knowledge priors from the LLM and builds an evidence relation graph for trusted-cluster identification. Under a 10% poisoning ratio, the method reduces the attack success rate from 47.5% to about 32.5%, but cannot fully eliminate poisoning and degrades notably at higher ratios.

(4) The proposed modules are integrated into an end-to-end military intelligence QA prototype with a three-layer architecture, deployed locally and offline. Comprehensive evaluation along five dimensions—answer accuracy, complex reasoning, robustness, trustworthiness, and efficiency—demonstrates the effectiveness of the proposed methods. This work provides methodological support for building a highly robust and trustworthy military intelligence QA system, with practical value

for intelligent decision support and information security under adversarial environments.

**Key words:** Retrieval-Augmented Generation; Military Intelligence Question Answering; Large Language Model; Dynamic Retrieval; Adversarial Robustness

## 目 录

## 第 1 章 绪论

### 1.1 研究背景与意义

现代战场的情报数据量近年来增长很快，来源也越来越杂，既有结构化的装备与编制数据，也有大量非结构化的新闻、评论、条令文本。面对这样的数据规模，单纯依靠人工分析往往跟不上节奏，分析人员需要花大量时间在信息检索和初步研判上。因此，借助自动化手段辅助情报问答与初步分析，是军事信息化中一个比较实际的需求。

近几年大语言模型（Large Language Model, LLM）的发展为这一需求提供了一种可能的技术路线。GPT、Claude、Gemini、Qwen、DeepSeek 等模型在通用问答、文本生成等任务上表现不错，在部分基准上已接近人类水平，并且以自然语言为交互接口，使用门槛较低，比较适合做成可对话的问答系统。

然而，将通用大语言模型直接应用于军事情报问答这一对精度与可信度要求极高的场景时，仍然面临若干根本性挑战。其一，大语言模型的内部知识停留在训练截止日期，无法实时反映战场态势的最新变化；其二，模型在通用语料上表现优异，但对装备参数、条令规范、战术术语等长尾、专业的军事知识掌握不足；其三，大模型固有的“幻觉”现象，使其在面对超出训练分布的问题时，倾向于编造看似合理但事实上错误的内容。在军事决策语境下，一次幻觉造成的误判可能引发严重的战略后果。

检索增强生成（Retrieval-Augmented Generation, RAG）通过在生成前从外部权威知识库中检索相关证据并将其注入大模型上下文，从机制上为缓解知识滞后与幻觉提供了直接路径。RAG 范式自 2020 年由 Lewis 等人正式提出以来，已迅速从朴素 RAG 演进至模块化 RAG、主动 RAG 等高级形态，并在医学、法律、金融等领域有不少应用。然而，当 RAG 应用于军事情报这一兼具高专业性、高对抗性、高复杂性的特殊场景时，仍然存在三类突出问题，如图 ?? 所示。

第一，**知识检索与领域适配不足**。互联网上公开的高质量军事问答数据集稀缺，现有公开军事数据集多面向新闻分析、事件抽取等任务，缺乏针对情报问答的标准化评测基准；通用嵌入模型在军事专有术语、装备型号、单位编制等长尾词汇上的语义对齐能力有限，导致检索召回的相关性偏低。

第二，**静态检索范式无法满足多跳推理需求**。装备-部署-地形-行动方案等多因素联动是军事情报的典型问题形态，朴素 RAG 一次性检索的 Top- $K$  文档难以同时覆盖各跳所需证据，模型被迫在证据残缺的状态下“硬编”，导致幻觉。

第三，**对抗环境下的可信度不足**。军事情报环境天然具有对抗性：来源庞杂、版本众多、可能存在敌方有意散布的虚假信息或认知域攻击。现有 RAG 普遍缺乏对检索结果可信度的系统评估与噪声过滤机制，敌方仅需向检索语料中注入少量精心构造的对抗性文本，就可能改变模型输出，带来安全风险。

上述问题表明，将 RAG 落地到军事情报问答场景，不能仅停留在已有通用方法的简单迁移层面，而需要从领域数据、检索机制与对抗鲁棒性三个维度系统性地重构方法体系。本文围绕这一目标开展研究，提出面向军事情报问答的鲁棒动态检索增强生成方法，对推动军事人工智能由实验室原型走向实战部署具有重要的理论意义与工程价值。

### 1.2 国内外研究现状

本节从大语言模型、文本检索技术、检索增强生成方法和军事情报智能应用四个方面，对与本课题相关的研究现状进行综述，并分析现有研究尚未充分解决的问题。






图 1-1 军事情报问答场景下 RAG 面临的三类核心挑战

### 1.2.1 大语言模型发展现状

语言模型的发展大体经历了四个阶段。早期的统计语言模型（如 N-gram）通过计算单词序列出现频率来估计文本生成概率，方法直观、可解释性强，但存在严重的数据稀疏与长距离依赖问题。随后，基于 RNN、LSTM 等结构的神经语言模型通过将文本嵌入连续向量空间，提升了模型对较长距离语言结构的建模能力。2017 年 Vaswani 等人 [?] 提出的 Transformer 架构，以自注意力机制取代循环结构，实现了完全并行化的训练，并奠定了当代大模型的基本范式。

预训练语言模型（Pre-trained Language Model, PLM）阶段以 BERT[?]、GPT-2、T5 等为代表，通过在大规模无标注语料上的自监督预训练，使模型获得了具备多义性与上下文敏感性的通用语言表示。在此基础上，研究者发现：当模型参数与训练数据同时扩大若干个数量级时，模型会涌现出零样本/少样本学习、复杂推理、指令遵循等新能力，这一现象被称为“涌现”（emergence）[?]。由此进入了大语言模型时代。

国际方面，OpenAI 的 GPT 系列、Anthropic 的 Claude 系列、Google 的 Gemini 系列、Meta 的 LLaMA 系列 [?] 等代表了当前最高水平。这些模型在通用任务上展现了卓越性能，并通过指令微调、人类反馈强化学习（RLHF）[?]、直接偏好优化（DPO）等对齐技术增强了对人类意图的理解能力。国内方面，阿里 Qwen 系列 [?]、深度求索 DeepSeek 系列 [?]、智谱 GLM 系列等开源模型的规模与性能逐步逼近国际前沿，并在多模态扩展、智能体框架、推理能力增强等方向有所创新。

尽管大语言模型取得了显著进展，其在专业领域的应用仍面临若干瓶颈：一是知识时效性受限于训练截止日期；二是长尾与领域专业知识在通用语料中占比有限，导致模型在专业问题上表现不稳定；三是幻觉问题 [?] 无法通过单纯增大模型规模根除。即便采用 LoRA[?]、Adapter、Prefix-Tuning 等参数高效微调（PEFT）[?] 技术注入领域知识，受限于训练数据规模与可更新的参数空间，模型仍可能在面对训练分布外的问题时输出不可靠内容。这促使研究者转向“模型 + 外部知识”的混合范式，即检索增强生成。

### 1.2.2 文本检索技术研究现状

文本检索是知识问答系统精准定位信息的关键。传统检索以稀疏方法为主，以 TF-IDF[?] 和 BM25[?] 为代表，通过统计词项频率与文档长度归一化进行相关性打分。BM25 兼具计算效率高、可解释性强、对短查询效果稳定的优点，至今仍是工业检索系统的强基线。其局限在于完全基于词项匹配，难以应对同义词、上下文歧义等语义现象。

随着深度学习的引入，稠密检索 (dense retrieval) 逐渐兴起。Karpukhin 等人 [?] 于 2020 年提出的 DPR (Dense Passage Retrieval) 采用双塔编码器分别将查询与文档映射到稠密向量空间，通过点积或余弦相似度实现语义匹配，在开放域问答上的表现优于 BM25。ColBERT[?]、SPLADE[?] 等后续工作进一步引入后期交互 (late interaction) 与稀疏-稠密混合表示，兼顾效率与精度。BGE[?]、E5[?]、M3E 等中文开源嵌入模型为中文语义检索提供了可直接调用的强力基线。

单一检索方法各有局限：稀疏检索难以处理语义相近但词形不同的查询，稠密检索则在罕见实体与精确字面匹配上偏弱。混合检索通过 Reciprocal Rank Fusion[?] 等方式融合两类方法的排序结果，已成为工业系统的事实标准。重排序模型 (reranker) 通过交互式编码进一步对初筛候选打分，通常能进一步提升 Top-10 的排序质量，但带来额外计算开销。

### 1.2.3 检索增强生成技术研究现状

Lewis 等人 [?] 于 2020 年提出 RAG 的最初范式：将检索得到的若干文档与原始查询拼接，作为生成模型的输入，端到端联合优化检索器与生成器。该范式被称为“朴素 RAG”，其核心思想已成为后续研究的基础。然而，朴素 RAG 在实际应用中暴露出诸多问题：检索质量直接决定生成质量，且单次检索难以覆盖复杂问题所需的全部证据；生成器对错误证据缺乏识别能力，可能将噪声内容直接复述为答案。

为缓解上述问题，研究界发展出“进阶 RAG”范式。在检索前阶段，研究者引入查询改写 [?]、HyDE (Hypothetical Document Embedding) [?]、查询扩展等技术，提高检索器与用户意图的对齐度；在检索后阶段，引入上下文压缩、相关性过滤、重排序等机制，提升注入大模型的证据质量。“模块化 RAG”进一步将检索、改写、生成、批判等步骤解耦为可独立优化的模块，并通过路由器或学习式策略协调模块协作。

近两年，“主动 RAG”和“动态 RAG”成为新的研究热点。代表性工作包括：Jiang 等人提出的 FLARE[?] 通过监测生成 token 的对数概率判断模型是否对当前生成不自信，进而触发即时检索；Asai 等人提出的 Self-RAG[?] 训练模型在生成时输出“是否需要检索”和“证据是否相关”等特殊标记；Yan 等人提出的 CRAG[?] 在检索后引入轻量评估器，根据相关性得分采取使用、修正或回退到 Web 检索三种策略；Trivedi 等人提出的 IRCOT[?] 将思维链推理与检索交错进行，使每一步推理都基于最新检索证据；Jeong 等人提出的 Adaptive-RAG[?] 根据问题复杂度自动选择直接回答、单次检索或多次检索三种路径。这些工作的共同特征是：将检索由“前置的静态步骤”转变为“贯穿生成过程的动态行为”，在复杂问答上一般能取得比朴素 RAG 更好的结果。

四种主要 RAG 范式的对比如表 ?? 所示。

尽管动态 RAG 在通用域问答上展现了优势，但其触发机制大多依赖单一信号（如 token 概率），对军事问答这类术语密集、推理链条长、对抗噪声多的场景缺乏针对性。此外，现有动态 RAG 工作普遍假设检索语料库是干净可信的，对“检索结果本身可能被污染”这一对抗设定鲜有讨论，难以直接迁移到军事情报这种安全敏感场景。RAG 范式的发展脉络如图 ?? 所示。

表 1-1 四种主要 RAG 范式对比

| 范式        | 检索时机        | 检索次数 | 查询改写      | 代表工作                       |
|-----------|-------------|------|-----------|----------------------------|
| 朴素 RAG    | 查询前固定一次     | 1    | 无         | Lewis 2020                 |
| 进阶 RAG    | 查询前 + 检索后处理 | 1    | 前置改写/扩展   | HyDE, Query Rewriting      |
| 模块化 RAG   | 可由路由器决定     | 1~N  | 模块化可插拔    | Self-RAG, CRAG             |
| 动态/主动 RAG | 生成过程中按需触发   | 1~N  | 基于生成状态自适应 | FLARE, IRCoT, Adaptive-RAG |




图 1-2 检索增强生成范式发展脉络

### 1.2.4 军事情报智能应用研究现状

国际上，美国国防高级研究计划局（DARPA）率先布局相关研究 [?]。2018 年启动的“AI Next”战役投入超过 20 亿美元，重点发展具备上下文推理能力的“第三波 AI”，强调可解释性与稳健性。2023 年后启动的“AI Forward”倡议进一步强调“可信赖 AI”，致力于开发可在国家安全任务中合规部署的可靠交互模型。

工业界方面，Scale AI 于 2025 年获得美国国防创新单元（DIU）多百万美元原型合同，主导“Thunderforge”项目，将 AI 智能体嵌入剧场级行动规划与兵棋推演，并与 Anduril 的 Lattice 平台、Microsoft 的大模型深度集成，支持快速生成行动方案、融合多源情报。同年，Scale AI 基于 Meta LLaMA 3 通过监督微调与人类反馈强化学习推出“Defense Llama”，在机密环境中运行，其训练数据涵盖军事条令、国际人道法及国防部伦理规范。Palantir 公司则面向战场边缘部署痛点开发了 Edge AI 平台，其核心为可在无人机、舰船、卫星等节点上轻量化运行的 Micro Models，并将大模型嵌入分类网络以实现端到端 AI 管线。

国内方面，通用大语言模型方面已具有相当竞争力，Qwen、DeepSeek、GLM 等系列在多个开源榜单上接近或超越国际同等参数规模模型。在军事 NLP 领域，Zhu 等人 [?] 于 2024 年发布的 CMNEE（Chinese Military News Event Extraction）数据集是少数面向中文军事新闻的开源数据集，主要面向事件抽取任务；面向军事问答与情报研判的开源数据集与评测基准仍较为稀缺。整体而言，国内军事大模型应用尚处于实验室原型向实战过渡的阶段，在领域知识注入深度、安全合规建设、边缘部署优化、对抗鲁棒性评测等方面与国际领先水平仍存在差距。军事 AI 重要节点的时间线如图 ?? 所示。




图 1-3 军事大语言模型应用重要节点时间线

## 1.3 论文主要研究内容与创新点

### 1.3.1 主要研究内容

针对前面提到的问题，本文围绕军事情报问答的 RAG 方法做了一些改进，主要内容包括以下四个方面，其中数据集构建偏支撑性，动态检索与对抗过滤是相对核心的方法工作。

(1) 军事情报领域知识库与对抗评测数据集构建。设计多源数据采集与多阶段预处理流程，构

建分类组织的军事情报知识库；按照“事实核验—关联分析—推理判断—综合生成”的能力链条，构造包含基础事实验证、复杂战术推理、对抗误导样本三类的军事情报问答数据集；并用这批数据对开源嵌入模型做 LoRA 微调，改善其在军事检索上的表现。

(2) 基于实时信息需求的动态检索与自适应查询重构机制。在生成过程中实时监测 Token 概率、注意力权重、输出熵三类内部信号，构造任务自适应的综合判别函数以决定检索触发时机；针对不同问题类型设计实体增强、实词聚焦、上下文融合三类自适应查询重构策略并实现策略选择器；并设计了多轮检索的终止条件，避免无限循环。

(3) 面向对抗环境的两阶段情报可信增强与噪声过滤机制。前置阶段基于语义聚类与领域特征增强对检索文档进行可疑识别与过滤；后置阶段从大模型提取内部知识先验，与外部证据构建证据关系图并进行一致性判定与冲突簇识别；建立证据覆盖度、证据对齐度、模型自一致性、不确定性四维评估指标，构建阈值与学习式相结合的可靠来源选择策略，支持低置信场景下的主动拒答与补检索。

(4) 系统集成与综合评估。将上述模块按数据层、控制层、安全防御层三层架构集成为端到端军事情报问答系统原型，本地离线部署，并从问答准确性、复杂推理能力、系统鲁棒性、信息可信度、检索与推理效率五个维度对系统进行综合性能评估。

### 1.3.2 主要创新点

本文的主要创新点可归纳为以下三个方面。

(1) 针对军事情报问答构建了一个带对抗样本的问答数据集。现有公开军事数据集大多面向事件抽取或新闻分析，缺少能直接用于问答评测、且含对抗样本的数据。本文参照情报研判流程构造了基础事实、复杂推理、对抗误导三类样本，采用机器初标加人工校验的方式保证质量，并配套整理了分类组织的知识库和证据出处信息。这部分更多是支撑性的数据工作，而非方法创新。

(2) 在 FLARE 等单信号触发方法基础上，用多信号融合改进动态检索。本文初期直接复用 FLARE 的单信号 (token 概率) 触发，但在军事术语密集文本上误触发较多，因此引入注意力权重和输出熵一起加权判断；并针对不同问题类型尝试了实体增强、实词聚焦、上下文融合三种查询重构方式。这些改动在多跳推理问题上带来一定提升，但也增加了推理延迟 (详见第 4 章)。该方法依赖对开源模型内部状态的白盒访问，不适用于闭源 API 模型。

(3) 针对检索库可能被污染的情况，设计了一种两阶段的过滤与可信判断方法。前置阶段用语义聚类配合领域特征过滤可疑文档，后置阶段用内部先验与外部证据做一致性比对识别冲突。该方法能在一定程度上降低投毒攻击的影响，但并不能完全消除——高投毒率下仍会受影响，过滤也存在误删正确文档的情况 (详见第 5 章)。

## 1.4 论文组织结构

本文共分为七章，章节关系如图 ?? 所示，各章主要内容如下。

第 1 章绪论。介绍研究背景与意义，综述国内外研究现状，给出论文研究内容与创新点，最后说明论文组织结构。

第 2 章相关理论与技术基础。介绍大语言模型、文本检索、检索增强生成、对抗环境下 RAG 安全等本文涉及的核心概念与方法，为后续章节提供理论与术语基础。

第 3 章军事情报知识库构建与领域嵌入模型微调。介绍多源军事数据采集与预处理流程、军事情报问答数据集的设计与构建，以及嵌入模型的 LoRA 领域微调方法，并给出相应的实验结果。

第 4 章基于实时信息需求的动态检索与自适应查询重构。介绍动态检索的总体框架、三类内部

信号的实时监测、综合判别函数、三类查询重构策略与循环推理流程，并给出相应的实验结果。

第 5 章面向对抗环境的情报可信增强与噪声过滤。介绍两阶段可信增强框架、语义聚类前置过滤、内外知识一致性后置评估、可靠来源选择与拒答机制，并讨论与第 4 章动态检索的协同。

第 6 章系统集成与综合性能评估。介绍系统三层架构、关键模块工程实现、部署环境与综合性能评估结果。

第 7 章总结与展望。总结主要工作与创新点，分析研究局限，展望未来研究方向。




图 1-4 论文章节关系示意图

## 1.5 本章小结

本章首先阐述了面向军事情报问答的检索增强生成方法研究的背景与意义，指出现代战场情报智能化对高精度、高可信问答系统的迫切需求；随后从大语言模型、文本检索、检索增强生成、军事情报智能应用四个方面综述了国内外研究现状，分析了现有研究尚未充分解决的三类问题；进而明确了本文的四项研究内容与三项主要创新点，并给出了论文整体组织结构。

## 第 2 章 相关理论与技术基础

本章对本文涉及的核心理论与关键技术进行系统介绍，包括大语言模型基础、文本检索与稠密表示、检索增强生成基础以及对抗环境下的 RAG 安全。这些内容将作为第 3-6 章方法描述的理论基础与术语基础。

### 2.1 大语言模型基础

#### 2.1.1 Transformer 架构与自注意力机制

Transformer 是当前主流大语言模型的基础结构。其核心思想是以自注意力（self-attention）机制取代循环网络，实现序列建模的完全并行化。给定输入向量序列  $X$ ，自注意力首先将其线性映射为查询、键、值三个矩阵  $Q$ 、 $K$ 、 $V$ ，然后通过缩放点积计算注意力权重，并对值向量进行加权求和：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \quad (2-1)$$

其中  $d_k$  为键向量的维度。多头注意力（multi-head attention）将上述操作并行执行  $h$  次，并将不同子空间的注意力结果拼接、线性变换得到最终输出。多头机制使模型能够同时关注序列中不同的语义子空间，是 Transformer 表达能力的关键来源。

为引入序列顺序信息，Transformer 采用位置编码（positional encoding）将每个位置映射为可加性的向量。在编码器/解码器结构中，自注意力与前馈网络交替堆叠，并辅以残差连接与层归一化以稳定训练。本文第 4 章提出的注意力权重监测机制将直接利用该结构中的注意力矩阵作为模型对历史上下文依赖的可量化信号。

#### 2.1.2 大语言模型的预训练与对齐

大语言模型的训练通常包括预训练、指令微调和对齐三个阶段。在预训练阶段，模型在大规模无标注语料上以自回归语言建模为目标，最大化下一个 token 的对数似然：

$$\mathcal{L}_{\text{PT}} = - \sum_t \log p_\theta(y_t | y_{<t}) \quad (2-2)$$

其中  $\theta$  为模型参数。预训练完成后，模型在生成第  $t$  个 token 时输出的是词表  $V$  上的概率分布  $p_\theta(\cdot | y_{<t})$ ，这一分布即是本文第 4 章基于 Token 概率监测进行检索触发的理论起点。

在指令微调（Supervised Fine-Tuning, SFT）阶段，模型在人工构造的指令-响应对上进一步训练，以学习遵循自然语言指令的能力。在对齐阶段，通过人类反馈强化学习（RLHF）[?] 或直接偏好优化（DPO）[?] 等方法，使模型输出更符合人类偏好。这一系列训练流程使大语言模型获得了在零样本/少样本条件下完成复杂任务的能力 [?, ?]。

#### 2.1.3 参数高效微调与 LoRA

大语言模型参数规模动辄数十亿乃至万亿级，对其进行全参数微调的计算与存储成本极高。参数高效微调（Parameter-Efficient Fine-Tuning, PEFT）[?] 通过在冻结主干参数的前提下引入少量可训练参数，以低成本实现领域适配。LoRA（Low-Rank Adaptation）[?] 是其中最具代表性的方法，其核心思想是将参数更新限制在低秩子空间内：

$$W = W_0 + \Delta W = W_0 + BA, \quad B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}, r \ll \min(d, k) \quad (2-3)$$

其中  $W_0$  为冻结的预训练权重,  $B$  与  $A$  为可训练的低秩矩阵, 秩  $r$  通常取 4 到 64。LoRA 训练效率高、显存占用低, 且可方便地在主干上挂载多个 LoRA 适配器以支持多任务切换。本文第 3 章将采用 LoRA 对开源嵌入模型进行军事领域微调。

#### 2.1.4 大语言模型的固有局限

尽管大语言模型表现卓越, 仍存在三类固有局限。一是**知识滞后**: 模型的内部知识停留在训练截止日期, 无法感知此后发生的新事实。二是**长尾知识不足**: 通用语料中军事术语、装备参数、条令规范等专业知识占比有限, 模型在这些方向上表现不稳定。三是**幻觉**: 当模型面对训练分布之外的问题时, 倾向于编造看似合理但事实错误的内容 [?]。这三类局限单靠扩大模型规模或参数高效微调难以根本解决, 从而催生了检索增强生成范式。

### 2.2 文本检索与稠密表示

#### 2.2.1 稀疏检索: TF-IDF 与 BM25

稀疏检索通过统计词项的文档频率与查询匹配度进行相关性打分。TF-IDF[?] 将词频与逆文档频率相乘以衡量词项的判别力, BM25[?] 在此基础上引入饱和函数与文档长度归一化, 是目前应用最广泛的稀疏检索方法。BM25 的计分公式为:

$$\text{BM25}(q, d) = \sum_{t \in q} \text{IDF}(t) \cdot \frac{\text{tf}_{t,d}(k_1 + 1)}{\text{tf}_{t,d} + k_1 \left(1 - b + b \frac{|d|}{\overline{|d|}}\right)} \quad (2-4)$$

其中  $\text{tf}_{t,d}$  为词项  $t$  在文档  $d$  中的频次,  $|d|$  为文档长度,  $\overline{|d|}$  为语料库平均文档长度,  $k_1$  与  $b$  为超参数。BM25 计算高效、可解释性强, 对短查询和精确字面匹配尤为有效, 至今仍是检索系统的强基线。其主要不足在于完全依赖词项匹配, 难以应对同义词、上下文歧义等语义现象。

#### 2.2.2 稠密检索: 双塔编码器与对比学习

稠密检索通过深度神经网络将查询与文档映射到稠密向量空间, 以向量相似度 (点积或余弦) 代替词项匹配进行检索。Karpukhin 等人 [?] 提出的 DPR 采用双塔编码器 (dual encoder), 分别对查询与文档独立编码, 使文档向量可预先建库并通过近似最近邻索引实现毫秒级检索。其训练目标通常为对比学习的 InfoNCE 损失:

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(q, d^+)/\tau)}{\exp(\text{sim}(q, d^+)/\tau) + \sum_{d^- \in \mathcal{N}} \exp(\text{sim}(q, d^-)/\tau)} \quad (2-5)$$

其中  $d^+$  为查询  $q$  的正样本文档,  $\mathcal{N}$  为负样本集,  $\tau$  为温度系数。负样本可来自批次内其他样本、BM25 难负样本或基于已有检索器的难负挖掘。BGE[?]、E5[?]、M3E 等开源嵌入模型为中文稠密检索提供了高质量的预训练基线。

#### 2.2.3 向量索引与混合检索

当文档规模达到百万乃至十亿量级时, 逐一计算向量距离不再可行, 需要近似最近邻 (Approximate Nearest Neighbor, ANN) 索引。FAISS[?] 是 Facebook 开源的高效 ANN 库, 支持 IVF (Inverted File)、PQ (Product Quantization) 等多种索引结构。HNSW (Hierarchical Navigable Small World)



[?] 采用多层小世界图结构, 在召回率与查询时延之间取得了良好平衡。本文第 3 章在构建军事情报知识库时将采用 FAISS+HNSW 组合作为底层向量索引方案。

稀疏与稠密两类方法在不同场景下各有优势: 稀疏检索对精确字面匹配与罕见实体更敏感, 稠密检索对语义相近表达更稳健。混合检索 (hybrid retrieval) 通过 Reciprocal Rank Fusion 等方法 [?] 融合两类方法的排序结果, 已成为工业系统的事实标准。RRF 的计分公式为:

$$\text{RRF}(d) = \sum_i \frac{1}{k + \text{rank}_i(d)} \quad (2-6)$$

其中  $\text{rank}_i(d)$  为文档  $d$  在第  $i$  个检索器结果中的排名,  $k$  为常数 (通常取 60)。重排序模型 (reranker) 则在初筛候选集上进行交互式编码, 通过 Cross-Encoder 对  $(q, d)$  联合编码并打分, 可显著提升 Top-K 排序质量, 但计算成本远高于双塔编码器, 通常仅用于 Top-100 量级的精排。

## 2.3 检索增强生成 (RAG) 基础

### 2.3.1 RAG 形式化定义

设用户查询为  $q$ , 外部知识库为  $\mathcal{D}$ , 检索器  $R$  从  $\mathcal{D}$  中召回 Top- $K$  文档作为证据集  $\mathcal{Z}$ , 生成器  $G$  基于  $q$  与  $\mathcal{Z}$  生成答案  $y$ 。RAG 的输出概率可分解为:

$$p(y | q) = \sum_{z \in \text{TopK } R(q, \mathcal{D})} p_G(y | q, z) \cdot p_R(z | q) \quad (2-7)$$

该公式表明 RAG 的最终生成质量由检索器与生成器联合决定。检索器召回质量决定可用证据, 生成器对证据的利用与忠实度决定最终回答的正确性。“检索-生成”两阶段的解耦带来了模块化优势, 但也意味着两类误差可能相互叠加: 若检索召回不相关或矛盾的证据, 生成器有可能将其错误复述; 反之若证据充分但生成器未能正确利用, 仍会产生幻觉。本文第 4、5 章正是分别从检索时机与证据可信度两个方向应对这一挑战。

### 2.3.2 RAG 范式数据流

RAG 自 2020 年提出以来经历了四种主要范式的演进 [?]: 朴素 RAG、进阶 RAG、模块化 RAG、动态/主动 RAG。四种范式的数据流对比如图 ?? 所示。

**朴素 RAG:** 在查询前一次性检索若干文档, 与原问题拼接后输入生成器, 结构简单但难以应对复杂问答。

**进阶 RAG:** 在朴素 RAG 基础上引入查询前处理 (如查询改写 [?], HyDE[?]) 与检索后处理 (如上下文压缩、重排序), 以提升检索与生成质量。

**模块化 RAG:** 将检索、改写、生成、批判等步骤抽象为可独立替换的模块, 并通过路由器协调模块间协作, 便于面向不同任务进行定制。

**动态/主动 RAG:** 将检索由前置静态步骤转变为贯穿生成过程的动态行为, 根据模型生成状态自适应触发与重构检索。FLARE[?], Self-RAG[?], CRAG[?], IRCOT[?], Adaptive-RAG[?], DRAGIN[?] 等均属此类。这一范式是本文第 4 章方法的直接前序工作, 但现有方法的触发与重构机制对军事情报这类术语密集、对抗噪声高的场景缺乏针对性。

### 2.3.3 RAG 评测指标体系

RAG 的评测涉及检索侧与生成侧两类指标。检索侧常用指标包括 Recall@ $k$  (前  $k$  个结果中包含正确文档的比例)、MRR (Mean Reciprocal Rank, 平均倒数排名)、nDCG@ $k$  (Normalized




图 2-1 四种主要 RAG 范式数据流对比

Discounted Cumulative Gain，归一化折损累积增益）。生成侧常用指标包括 Exact Match（精确匹配）、F1（基于词级重合度的调和均值）、ROUGE 以及面向 RAG 的专属指标 Faithfulness（忠实度，回答与证据的事实一致性）、Answer Relevance（答案与问题的相关度）[?]。本文第 3-6 章将根据不同评测目标选用上述指标。

2.4 对抗环境下的 RAG 安全

2.4.1 RAG 系统的攻击面

与传统大语言模型相比，RAG 引入了外部知识库与检索过程，从而扩大了攻击面。主要攻击类型包括：

- (1) **检索语料投毒 (corpus poisoning)**：攻击者向知识库注入伪造或篡改的文档，使检索器召回错误证据 [?, ?]。
- (2) **查询注入 (query injection)**：通过精心构造的查询使检索器召回特定文档。
- (3) **提示注入 (prompt injection)**：在检索到的文档中嵌入“忽略上文”“你现在是…”等指令，劫持生成器行为 [?, ?]。
- (4) **误导性证据混合**：在大量真实证据中混入少量似是而非的对抗性陈述，依靠模型对证据的整体加权迫使其输出偏离真值 [?]

表 ?? 给出了上述攻击类型与典型方法的对照。

表 2-1 RAG 攻击类型与典型方法对照

| 攻击类型    | 主要手段   | 攻击目标   | 典型工作                      |
|---------|--------|--------|---------------------------|
| 检索语料投毒  | 注入伪造文档 | 召回错误证据 | PoisonedRAG               |
| 查询注入    | 精心构造查询 | 诱导特定召回 | Adversarial Query         |
| 提示注入    | 文档中嵌指令 | 劫持生成器  | Indirect Prompt Injection |
| 误导性证据混合 | 少量对抗证据 | 改变最终回答 | ConfusedPilot             |

### 2.4.2 现有防御思路

针对上述攻击，现有研究主要从三类思路展开。一是**前置过滤**：通过相关性阈值、聚类、异常检测等方式在检索后即剔除可疑文档。二是**生成端自反思**：Self-RAG、CRAG 等通过让模型自我评估证据相关性与回答可信度，在低置信场景下触发回退或补检索 [?, ?]。三是**一致性检测**：将外部证据与模型内部知识先验或多源证据相互对照，识别冲突并据此调整生成行为。这三类思路各有优势，也各有局限：前置过滤可能将真实但少数派的证据误判；生成端自反思依赖模型自身的可靠性评估能力；一致性检测在大语料、复杂证据下计算成本较高。本文第 5 章将提出语义聚类前置过滤与一致性后置评估相结合的两阶段防御框架，综合上述思路的优势。

### 2.4.3 评测维度

对抗鲁棒性的评测主要从以下指标展开：

- (1) **攻击成功率** ASR (Attack Success Rate)：模型输出与攻击者目标一致的样本比例，值越低越好；
- (2) **性能下降率** PDR (Performance Drop Rate)：投毒条件下相对干净条件的准确率下降幅度，值越低越好；
- (3) **召回纯净度** RP (Recall Purity)：经过滤后的证据集中真实文档所占比例；
- (4) **误报率** FPR (False Positive Rate)：真实证据被误判为投毒的比例；
- (5) **拒答精确率/召回率**：在真值无法判断时主动拒答的正确性。

本文第 5 章将基于上述指标对所提防御方法进行系统评测。

## 2.5 本章小结

本章围绕本文方法所依赖的核心理论与技术，依次介绍了大语言模型的结构、预训练与对齐流程、参数高效微调以及固有局限；文本检索的稀疏、稠密、混合方法及重排序技术；检索增强生成的形式化定义、范式演进与评测指标体系；以及对抗环境下 RAG 系统的攻击面、防御思路与评测维度。这些内容为后续第 3-6 章的方法设计与实验评估提供了理论与术语支撑。

### 第 3 章 军事情报知识库构建与领域嵌入模型微调

#### 3.1 引言

军事情报问答系统的效果，很大程度上取决于底层知识库的质量和嵌入模型对军事语义的匹配能力。军事文本的术语和表述比较专业，知识库需要尽量覆盖全面并且能追溯到出处；而通用嵌入模型在军事术语、装备型号、单位编制这类长尾词汇上的匹配能力有限，直接拿来用，检索召回的相关性往往不太理想。

针对上述问题，本章主要开展三方面工作：第一，设计多源军事数据采集与多阶段预处理流程，构建分类组织的军事情报知识库；第二，按情报研判的能力链条设计并构建包含基础事实验证、复杂战术推理、对抗误导样本三类的军事情报问答数据集；第三，以构建的数据集为正样本对开源嵌入模型进行 LoRA 领域微调，提升其在军事检索任务上的表现。最后给出对应的实验结果。

#### 3.2 多源军事数据采集与预处理

##### 3.2.1 数据来源

为兼顾数据覆盖度与合规性，本文采用多源数据采集策略，主要数据来源包括：

- (1) **CMNEE 军事新闻事件抽取数据集** [?]: Zhu 等人于 2024 年发布的中文军事新闻事件抽取数据集，是当前少数公开可用的中文军事 NLP 数据集，包含约 17 万句子的军事新闻、标注了试验、部署、冲突等多类事件。本文利用其作为军事新闻类语料的基础。
- (2) **公开军事条令与法规**：包括我军公开的部分条令条例、国际军事条约、国际人道法等公开文档，以及美军 Field Manuals 等已解密的开源军事条令。
- (3) **军事百科、防务评论与公开军事书籍**：包括公开的军事百科页面、权威防务评论、军事学术期刊等。
- (4) **合作单位提供的脱密脱敏语料**：经合作单位审核脱密后提供的军事情报样本，用于补充实际情报问答场景。

上述数据均为开源或经过严格脱密处理的资料，使用过程符合相关合规要求。各类数据来源的规模与采集方式如表 ?? 所示，总语料量约 31.5 万段落、86 万 token 量级。

表 3-1 多源军事数据来源汇总

| 数据类型 | 主要来源          | 获取方式   | 段落数     | Token 数 (万) |
|------|---------------|--------|---------|-------------|
| 军事新闻 | CMNEE 等开源数据集  | 开源下载   | 174,328 | 42.8        |
| 军事条令 | 公开条令、解密 FM 系列 | 公开网站爬取 | 53,472  | 18.9        |
| 军事百科 | 军事百科、专业网站     | 公开网站爬取 | 31,854  | 11.7        |
| 防务评论 | 权威防务媒体公开文章    | 公开网站爬取 | 47,690  | 9.4         |
| 脱密语料 | 合作单位提供        | 内部交付   | 7,415   | 3.6         |
| 合计   | —             | —      | 314,759 | 86.4        |

### 3.2.2 多阶段预处理流程

针对军事数据的特殊性，本文设计了“文本清洗—实体识别—情报分块—向量化索引”四阶段预处理流程，如图 ?? 所示。




图 3-1 军事情报知识库构建流程图

**文本清洗阶段**主要完成 HTML 标签去除、特殊字符过滤、全角半角统一、标点规范化、繁简体转换等基础工作。针对军事文本中常见的表格、列表结构，采用启发式规则保留其层次信息；针对脚注、引用等结构，单独抽取并保留与正文的对应关系，以便后续证据追溯。

**实体识别阶段**采用预训练 NER 模型（基于 BERT-CRF 架构）抽取军事文本中的关键实体，包括武器装备（如歼-20、东风-41）、作战单位（如第 72 集团军、航母打击群）、地理位置（如某基地、某海域）、时间表达（如 2024 年军演、部署周期）等。在通用 NER 模型基础上，结合公开军事词典与人工补充实体表对模型进行少量样本微调，最终在测试集上取得 91.2% 的实体识别 F1。识别到的实体进一步通过基于编辑距离与同义词表的归一化模块映射到统一标识，以便跨文档对齐。

**情报分块阶段**将文档切分为适合检索的片段。本文对比了三类分块策略：固定长度切分（256/512/1024 token）、按语义边界切分、滑窗切分。考虑到军事情报中条令条款、装备参数等结构化信息往往跨段落出现，本文最终采用语义边界优先、辅以滑窗（窗口 512 token，重叠 64 token）的混合策略，并保留段落标题、章节编号作为元信息附加在每个分块上。

**向量化索引阶段**采用经第 ?? 节微调后的领域嵌入模型对每个分块进行编码，构建 FAISS HNSW 向量索引（ $M = 32$ , efConstruction = 200）；同时构建基于 Elasticsearch 的稀疏倒排索引，以支持混合检索。每个分块附带元数据，包括来源、采集时间、权威性等级、脱敏标识等，用于后续证据可信度评估。

### 3.2.3 知识库的分类组织

军事情报包含装备、条令、态势、案例等多种异质内容。为支持按类目过滤的高效检索，本文将知识库按四类组织：（1）**装备类**涵盖武器装备型号、参数、性能、部署信息；（2）**条令类**包括各类军事条令、规范、作战指南；（3）**态势类**包括军事新闻、部署动态、演习与冲突事件；（4）**案例类**包括历史战例、战术分析、经验总结。每个分块根据其内容主体被分配到一个主类目，并允许跨类目的辅助标签，以支持多视角检索。最终知识库各类目分块统计如表 ?? 所示。

表 3-2 军事情报知识库分类组织统计

| 类目           | 装备类    | 条令类    | 态势类     | 案例类    |
|--------------|--------|--------|---------|--------|
| 分块数          | 78,349 | 53,472 | 145,826 | 37,112 |
| 占比           | 24.9%  | 17.0%  | 46.3%   | 11.8%  |
| 平均长度 (token) | 412    | 528    | 386     | 467    |

3.3 军事情报问答数据集构建

3.3.1 三类样本设计

为系统评测面向军事情报问答的检索增强生成方法，本文按情报研判的能力链条设计了三类问答样本，如表 ?? 所示。

表 3-3 军事情报问答数据集三类样本设计

| 样本类型   | 评测能力    | 样本数   | 平均跳数 |
|--------|---------|-------|------|
| 基础事实验证 | 事实精确召回  | 510   | 1.0  |
| 复杂战术推理 | 多跳推理与归纳 | 446   | 2.7  |
| 对抗误导样本 | 对抗鲁棒性   | 320   | 1.8  |
| 合计     | —       | 1,276 | 1.8  |

**基础事实验证类样本**针对装备参数、条令要点、事件事实等可直接核对的问题。这类样本的答案应能在知识库中找到明确证据片段，主要考察检索精度与生成忠实度。

**复杂战术推理类样本**需要跨段落、跨文档证据进行归纳、对比与判断。例如“某型装备部署至 X 地形后，对作战半径及行动方案的潜在影响”，需要模型综合装备性能、地形条件、作战条令多个方面进行推理。这类样本是评测多跳推理能力的核心。

**对抗误导样本**针对模型在含有噪声或对抗性证据时的鲁棒性。具体做法是在已构造的事实/推理样本基础上，向其证据集中按一定比例注入伪造或矛盾的陈述，并标注真值答案与对抗注入。这类样本是评测第 5 章方法对抗鲁棒性的关键。

3.3.2 样本构造与标注流程

数据集构造采用“机器初标 + 人工校验”双阶段流程，如图 ?? 所示。

**机器初标阶段**从知识库中随机或按主题采样若干文档片段，将其与精心设计的提示模板一起输入大语言模型，自动生成候选问答对。提示模板针对三类样本分别设计：对基础事实类，要求模型生成事实型问答并标出唯一答案与证据句；对复杂推理类，要求模型生成跨段落问题，并标出“关键推理依据点”清单；对对抗误导类，进一步要求模型生成与原始事实相矛盾的伪造陈述，作为后续对抗注入的素材。机器初标采用 Qwen2.5-72B 等高性能开源模型在本地完成，避免敏感数据上传。

**人工校验阶段**由 4 名具备军事相关背景的人员对机器初标的样本逐条审查，重点核查四方面：术语表述准确、证据可对齐、推理链条完整、战术逻辑自洽。校验员可对样本进行修订、合并或剔除。为保障一致性，每批样本由两名校验员独立审查，差异部分由第三名校验员裁定。最终人工校验的 Cohen’s  $\kappa$  一致性系数达到 0.82。





图 3-2 问答样本构造与质量校验流程

### 3.3.3 样本字段设计

为支持后续多角度评测，每条样本采用结构化字段组织，主要字段如图 ?? 所示。



核心创新：evidence\_chunks 与 key\_reasoning\_points 提供可追溯证据；  
adversarial\_inject 提供对抗载荷；source\_meta 支持证据可信度评估

图 3-3 军事情报问答数据集样本字段结构

其中 evidence\_chunks 字段记录答案的证据出处，使每个样本均具备“有据可查”的可解释性，便于后续 Faithfulness 评测与人工复核。

### 3.3.4 数据集质量保障

为保证数据集可用性与可靠性，本文设计了四项质量保障措施：

(1) **格式与完整性检查**：对每条样本自动校验字段齐全、类型正确，发现并修复 47 条字段缺失样本。

(2) **证据一致性校验**：要求 `answer` 能够在 `evidence_chunks` 中找到依据；对推理类样本检查 `key_reasoning_points` 是否覆盖关键推理步骤。证据一致率达 96.8%。

(3) **抽样复核与问题回收**：按 10% 比例抽取样本进行人工复核，重点检查装备型号、数字单位、时间线、地名/组织名等易错字段。复核发现并修订 39 条样本。

(4) **一致性复查**：对同一主题或同一来源的样本进行横向比对，检查同一事实在不同样本中表述是否冲突，最终统一表述并注明适用条件与时间范围。

四项措施迭代执行直至数据集稳定。最终数据集按 8:1:1 比例划分为训练集（1,020 条）、验证集（128 条）、测试集（128 条）。

## 3.4 嵌入模型的领域适配微调

### 3.4.1 基线嵌入模型选择

为在中文军事文本上获得最佳基线性能，本文对比了 BGE-base-zh、BGE-large-zh、BGE-M3、E5-large-zh、M3E-large 等主流开源中文嵌入模型。综合考虑模型规模、性能、多功能性（密集向量/稀疏向量/Multi-vector）以及对长文档的支持，最终选定 BGE-M3[?] 与 BGE-large-zh-v1.5 作为后续微调的基线模型，并以二者中表现更佳者作为主线。

### 3.4.2 LoRA 微调策略

为兼顾效率与性能，本文采用 LoRA 对基线嵌入模型进行领域微调。在嵌入模型的查询编码器与文档编码器的所有注意力层（ $Q$ 、 $K$ 、 $V$  投影）上挂载 LoRA 适配器，秩  $r$  在验证集上从  $\{4, 8, 16, 32, 64\}$  中调优选取（最终为  $r = 16$ ，详见 ?? 节实验），初始学习率  $1 \times 10^{-4}$ ，采用余弦退火与线性 warm-up，batch size 为 128，训练 10 个 epoch，AdamW 优化器 [?]

### 3.4.3 训练目标与负样本构造

采用对比学习的 InfoNCE 损失（公式 2-5）作为训练目标，温度系数  $\tau$  设为 0.05。正样本为 ?? 节构造的“问题-证据片段”对；负样本采用以下两种方式构造：

(1) **批内负样本 (in-batch negatives)**：将同一批次中其他样本的证据片段作为当前样本的负样本，效率高但难度较低；

(2) **BM25 难负样本 (BM25 hard negatives)**：对每个问题，使用 BM25 召回前 50 名文档中不属于正样本证据的片段作为难负样本，提升模型对细微语义差异的判别能力。

训练过程中，将上述两类负样本按 1:1 比例混合，以兼顾训练效率与判别能力。整体 LoRA 微调框架如图 ?? 所示。






图 3-4 嵌入模型 LoRA 微调框架

### 3.5 实验设计与结果

#### 3.5.1 实验环境

实验在一台配置 NVIDIA A100 40GB 单卡的服务器上完成 (CUDA 12.1、cuDNN 8.9), CPU 为 Intel Xeon 32 核, 内存 256 GB。软件方面使用 Python 3.10、PyTorch 2.1.0、HuggingFace Transformers 4.40、PEFT 0.10、FAISS 1.7.4、Elasticsearch 8.13。受限于单卡显存, 本文未对 7B 以上规模模型或全参数微调做更大 batch 的尝试。所有实验在本地完成, 不依赖外网。

嵌入模型微调主要超参: 嵌入维度 1024, 最大序列长度 512, LoRA 秩  $r = 16$ 、 $\alpha = 32$ 、dropout 0.05, 仅在注意力层的  $Q$ 、 $K$ 、 $V$  投影上挂载适配器; 优化器 AdamW, 学习率  $1 \times 10^{-4}$ , warmup 比例 0.05, 余弦退火, batch size 64 (受显存限制经梯度累积等效到 128), 训练 10 个 epoch, 对比学习温度  $\tau = 0.05$ 。检索阶段 chunk size 取 512 token、overlap 64 token, 向量检索 top- $k$  取 20, 重排序对 top-50 候选打分后保留 top-10。

#### 3.5.2 评测指标

针对检索任务采用以下指标: Recall@ $k$  ( $k=1, 5, 10, 20$ )、MRR、nDCG@10。所有指标在测试集上计算, 并报告 5 个不同随机种子下的均值与标准差。

#### 3.5.3 嵌入模型对比 (Exp 3-1)

表 ?? 给出五种基线嵌入模型在零样本与微调后的检索表现。几点观察: (1) 微调后各模型 Recall@10 都有提升, 平均涨了 7 个百分点左右, 说明领域微调有用, 但提升幅度并没有想象中——训练集仅约 1000 条, 数据量制约了增益; (2) BGE-M3 与 BGE-large-zh 微调后接近, Recall@10 分别约 79.1% 和 78.6%; (3) E5-large、M3E-large 微调后与 BGE 系列差距不大; (4) 综合性能和训练成本, 后续以 BGE-large-zh-v1.5 为主线。需说明的是, 微调对不同查询的改善并不均衡: 装备型号、参数类精确查询改善较明显, 口语化的态势类问题改善有限。

表 3-4 不同嵌入模型在军事检索任务上的性能 (Exp 3-1)

| 模型           | 零样本            |                | LoRA 微调                          |                                  |                                  |
|--------------|----------------|----------------|----------------------------------|----------------------------------|----------------------------------|
|              | R@10           | MRR            | R@10                             | MRR                              | nDCG@10                          |
| BM25 (基线)    | 58.4 $\pm$ 0.0 | 41.6 $\pm$ 0.0 | —                                | —                                | —                                |
| BGE-base-zh  | 67.2 $\pm$ 0.5 | 49.7 $\pm$ 0.6 | 74.6 $\pm$ 0.6                   | 58.3 $\pm$ 0.7                   | 62.1 $\pm$ 0.6                   |
| BGE-large-zh | 71.4 $\pm$ 0.4 | 53.2 $\pm$ 0.5 | 78.6 $\pm$ 0.5                   | 62.7 $\pm$ 0.5                   | 65.8 $\pm$ 0.5                   |
| BGE-M3       | 72.3 $\pm$ 0.4 | 54.0 $\pm$ 0.5 | <b>79.1 <math>\pm</math> 0.5</b> | <b>63.4 <math>\pm</math> 0.5</b> | <b>66.3 <math>\pm</math> 0.4</b> |
| E5-large-zh  | 69.6 $\pm$ 0.5 | 51.7 $\pm$ 0.6 | 77.2 $\pm$ 0.6                   | 61.1 $\pm$ 0.6                   | 64.4 $\pm$ 0.5                   |
| M3E-large    | 68.3 $\pm$ 0.5 | 50.4 $\pm$ 0.6 | 76.0 $\pm$ 0.6                   | 60.2 $\pm$ 0.6                   | 63.3 $\pm$ 0.6                   |

### 3.5.4 LoRA 与全参数微调对比 (Exp 3-2)

在 BGE-large-zh 上对比了 LoRA 与全参数微调 (表 ??)。LoRA 的 Recall@10 比全参数微调低 0.7 个百分点, 差距不大; 考虑到全参数微调在单卡 40GB 上要开梯度检查点才能跑、训练时间也长得多, 本文最终选 LoRA。这里要承认, 由于数据量偏小, 全参数微调本身也没能把性能拉开, 二者差距不明显的部分原因正是数据规模限制了全参数微调的发挥。

表 3-5 LoRA 与全参数微调对比 (BGE-large-zh, Exp 3-2)

| 微调方式            | 可训练参数  | R@10 | MRR  | 训练时间 (h) | 显存 (GB) |
|-----------------|--------|------|------|----------|---------|
| 不微调             | 0      | 71.4 | 53.2 | —        | —       |
| LoRA ( $r=16$ ) | 1.18 M | 78.6 | 62.7 | 1.6      | 17.8    |
| 全参数微调           | 326 M  | 79.3 | 63.2 | 6.8      | 38.5    |

### 3.5.5 LoRA 秩超参敏感性 (Exp 3-3)

图 ?? 展示了 LoRA 秩  $r$  从 4 到 64 变化时, 验证集 Recall@10 与训练显存的关系。可以看出,  $r = 16$  时性能与显存的折中最优, 进一步增大  $r$  收益递减。

### 3.5.6 其他实验简要结果

表 ?? 汇总了 Exp 3-4 (负样本构造)、Exp 3-5 (分块策略)、Exp 3-6 (重排序) 三组实验的主要结果。

从表 ?? 可以看出几点。负样本方面, 混合负样本比单用批内负样本好, 但相比只用 BM25 难负样本的提升其实有限 (不到 2 个百分点), 说明难负样本是主要贡献来源。分块策略方面, 固定 256 token 效果最差——军事条令、装备参数常跨句出现, 切太碎会把完整语义切断; 固定 1024 token 也不好, 块太大引入无关内容稀释语义; 语义边界加滑窗相对最好, 但和 512 token 固定切分只差约 1.2 个百分点, 并没拉开太多。重排序方面, 加 Cross-Encoder 能提升约 2.7 个百分点, 但每次查询多花约 80 ms, 多轮检索下这部分开销会累加, 因此本文只在最终结果展示阶段启用重排序, 动态检索中间轮次不启用。


图 3-5 LoRA 秩  $r$  对验证集性能与显存占用的影响

表 3-6 Exp 3-4 ~ Exp 3-6 主要结果汇总

| 实验             | 对比设置                 | R@10        | nDCG@10     |
|----------------|----------------------|-------------|-------------|
| Exp 3-4: 负样本构造 | 仅批内负样本               | 73.1        | 60.4        |
|                | 仅 BM25 难负样本          | 76.8        | 64.2        |
|                | 混合负样本 (本文)           | <b>78.6</b> | <b>65.8</b> |
| Exp 3-5: 分块策略  | 固定 256 token         | 72.5        | 60.1        |
|                | 固定 512 token         | 77.4        | 64.6        |
|                | 固定 1024 token        | 74.0        | 61.8        |
|                | 语义边界 + 滑窗 (本文)       | <b>78.6</b> | <b>65.8</b> |
| Exp 3-6: 重排序   | 仅稠密检索                | 78.6        | 65.8        |
|                | 稠密检索 + Cross-Encoder | <b>81.3</b> | <b>69.1</b> |

### 3.5.7 案例分析 (Exp 3-7)

表 ?? 给出一个典型案例：查询“歼-20 隐身涂层在 X 频段的雷达反射截面”，对比微调前后的 Top-3 召回。微调前模型主要召回与“歼击机”“隐身”相关的泛化文档，与原查询的精确技术参数关联度不足；微调后能召回到与歼-20 雷达截面更相关的段落。不过也要说明，这类改善主要出现在含明确实体和型号的查询上，对不含具体型号、表述笼统的查询，微调前后召回差别并不明显。

表 3-7 微调前后 Top-3 召回对比案例 (Exp 3-7)

| 排名 | 微调前 BGE-large        | 微调后 BGE-large        |
|----|----------------------|----------------------|
| 1  | 第五代隐身战斗机的设计原理与气动外形   | 歼-20 主要技术参数与雷达反射截面分析 |
| 2  | 雷达反射截面 (RCS) 概念及测量方法 | 隐身涂层在 X/Ka 频段的吸波性能   |
| 3  | 隐身战机在现代防空体系中的作用      | 第四与第五代战机 RCS 数量级对比   |

## 3.6 本章小结

本章做的是数据和检索表示层面的基础工作。整理了多源军事数据的采集与预处理流程，形成约 31.5 万段落、按四类组织的知识库；参照情报研判流程构造了三类、共 1276 条问答样本并做了质量校验。用这批数据对 BGE 嵌入模型做 LoRA 微调后，军事检索 Recall@10 从 71.4% 提升到约 78.6%，加 Cross-Encoder 重排序后约 81.3%。需要指出，受数据规模限制，微调提升幅度有限，且对不同类型查询改善不均衡。本章的数据集和微调模型为第 4、5 章实验提供了基础。

## 第 4 章 基于实时信息需求的动态检索与自适应查询重构

### 4.1 引言与问题分析

军事情报里有不少问题需要把多个方面的信息串起来推理。比如“分析某地区军事部署变化对周边安全环境的潜在影响”这类问题，模型得同时拿到“部署的具体动向”“相关地理与战略环境”“周边安全态势”几块互补的证据。朴素 RAG 一次性检索的 Top- $K$  文档很难同时覆盖这些证据，模型只能在信息不全的情况下硬推中间结论，结果就容易出幻觉。

一个比较自然的改进方向，是把检索从生成前的一次性步骤，改成生成过程中按需触发——也就是近两年的动态 RAG[?, ?, ?, ?]。本文最初直接复用了 FLARE 的做法，即只看下一个 token 的对数概率来决定是否检索。但在军事文本上试下来，这种单信号触发的误触发比较多：军事术语、型号编号本身在通用语料里就少见，模型生成这些词时概率天然偏低，结果经常在并不缺知识的地方触发检索，既增加延迟又引入无关文档。为此本文又试着引入注意力权重和输出熵两个信号，和概率信号一起加权判断，误触发的情况有所缓解。这部分尝试和取舍构成了本章的主要内容。需要强调，这些信号都要求能拿到模型生成时的 logits 和注意力矩阵，因此本方法只适用于开源白盒模型，闭源 API 模型用不了。

具体来说，本章想解决三个问题：（1）什么时候触发检索；（2）触发后查询怎么写；（3）多轮检索怎么收敛、不至于越检越偏。

### 4.2 动态检索总体框架

#### 4.2.1 框架概述

本章提出的动态检索-自适应查询重构机制总体框架如图 ?? 所示，主要包含三个核心组件：实时信息需求检测器  $D$ 、自适应查询重构器  $Q$ 、循环推理控制器  $C$ 。在生成过程中，每生成若干 token 后，检测器  $D$  综合三类内部信号判断是否存在知识缺口；当判别得分超过阈值时，重构器  $Q$  根据问题类型与生成状态从三类策略中选择最合适的查询重构方式并产出新查询，进而触发检索；控制器  $C$  决定何时合并证据、何时继续生成、何时终止循环。

形式化地，整体流程可表示为：

$$y_t \sim p_\theta(\cdot \mid q, y_{<t}, \mathcal{Z}_t) \quad (4-1)$$

$$\mathcal{Z}_{t+1} = \begin{cases} \mathcal{Z}_t \cup \text{Retrieve}(Q(q, y_{\leq t}, \text{Attn})), & \text{若 } D(y_t, p_\theta, \text{Attn}) > \tau \\ \mathcal{Z}_t, & \text{否则} \end{cases} \quad (4-2)$$

其中  $q$  为原始查询， $y_{<t}$  为已生成 token 序列， $\mathcal{Z}_t$  为截止第  $t$  步累积的证据集合，Attn 为最近若干层的注意力矩阵， $\tau$  为触发阈值。该流程在生成过程中反复执行，直至达到终止条件。

#### 4.2.2 与已有方法的关系

本文方法和几个相关工作的区别如下。与 FLARE[?] 相比，本文用三类信号联合判别，主要是为了缓解单信号在军事文本上误触发多的问题；与 Self-RAG[?] 相比，本文方法不需要对大模型做专门训练 (training-free)，但代价是触发判断依赖白盒内部状态、只能用于开源模型；与 IRCot[?] 相比，本文的检索触发由生成状态驱动而非预设步数。另外本文针对军事场景试了几种查询重构策略。需要说明，这些区别更多是工程实现和适配层面的，并非范式上的根本不同。




图 4-1 动态检索-自适应查询重构总体框架

### 4.3 实时信息需求检测机制

#### 4.3.1 三类内部信号

为准确感知大模型生成过程中的知识缺口，本文同时利用三类相互补充的内部信号。

(1) **Token 概率信号**  $s_p$ 。模型在生成第  $t$  个 token 时输出的负对数概率反映了该 token 的不确定性，越大则不确定性越高：

$$s_p(t) = -\log p_\theta(y_t | q, y_{<t}) \quad (4-3)$$

当涉及专业军事实体（武器型号、单位编制等）时，若模型在训练语料中很少见到对应表达，其负对数概率会显著升高，提示潜在的知识缺口。

(2) **注意力权重信号**  $s_a$ 。注意力权重反映了当前生成位置对历史上下文的依赖程度。在多跳推理场景中，模型若对问题中的关键实体呈现“高注意力依赖但输出低置信度”的异常模式，往往意味着需要外部证据支撑。本文从最后  $L$  层（默认  $L = 4$ ）取自注意力矩阵  $A^{(l)}$ ，对问题中军事实体位置的依赖度取多头平均后再求均值，与生成置信度的补集相乘：

$$s_a(t) = \frac{1}{|E|} \sum_{i \in E} \bar{A}_{t,i}^{(l)} \cdot (1 - p_\theta(y_t | \cdot)) \quad (4-4)$$

其中  $E$  为问题中军事实体的位置索引集（来自第 3.2.2 节 NER 模块输出）， $\bar{A}$  为多头注意力平均后的依赖分布。该信号能够捕捉“模型紧盯关键实体却仍不自信”这一典型的多跳推理困境。

(3) **输出熵信号**  $s_h$ 。词表上的分布熵刻画了模型在当前位置对不同候选 token 的分歧程度：

$$s_h(t) = -\sum_{v \in V} p_\theta(v | \cdot) \log p_\theta(v | \cdot) \quad (4-5)$$

熵值突增意味着模型面临多条候选路径且彼此概率相近，往往出现在生成战术分析或情报研判结论时需要在多种可能性中作出选择的位置。引入权威外部证据可以显著降低这种分歧。

4.3.2 综合判别函数

上述三类信号取值范围不同，且对不同任务的敏感度也不同，需要进行标准化与加权融合。本文对每个信号在最近  $W$  个生成步上做滑动窗口标准化，得到 z-score 形式的标准化信号  $\tilde{s}_p$ 、 $\tilde{s}_a$ 、 $\tilde{s}_h$ ，并以加权和形成综合判别函数：

$$S(t) = w_p \cdot \tilde{s}_p(t) + w_a \cdot \tilde{s}_a(t) + w_h \cdot \tilde{s}_h(t), \quad w_p + w_a + w_h = 1 \tag{4-6}$$

当  $S(t) > \tau$  时触发检索。阈值  $\tau$  基于验证集上的 PR 曲线确定，使触发率与召回的有效证据比例达到良好折中。三类信号在一个典型军事推理样本中的演化情况如图 ?? 所示。




图 4-2 三类内部信号随生成步演化曲线示意（触发点高亮）

4.3.3 任务自适应权重调整

不同类型的军事情报问题对三类信号的依赖度有所差异。本文针对三类典型任务给出默认权重配置，如表 ?? 所示。

表 4-1 任务自适应权重默认配置

| 任务类型   | $w_p$ | $w_a$ | $w_h$ | 设计直觉              |
|--------|-------|-------|-------|-------------------|
| 装备参数查询 | 0.6   | 0.2   | 0.2   | 概率信号直接反映“是否见过该事实” |
| 战略态势分析 | 0.2   | 0.5   | 0.3   | 注意力对关键实体的依赖最重要    |
| 对抗环境验证 | 0.2   | 0.2   | 0.6   | 熵值反映多路径选择困境       |

问题类型识别采用轻量级文本分类器实现，输入查询经短文本嵌入后通过 MLP 输出三类概率，最终选择概率最高的类别对应的权重配置。当问题类型概率分布较平坦（最大概率与次大概率差小于 0.15）时退回到三类权重的均值。该分类器在验证集上达到 92.8% 的准确率。

#### 4.3.4 触发阈值的选择

触发阈值  $\tau$  的选取存在权衡：阈值过低将导致频繁不必要的检索，引入额外延迟与噪声；阈值过高则可能错过真实的知识缺口。本文在验证集上以“召回率（成功在缺口处触发检索的比例）”与“精确率（触发检索后确实带来证据增益的比例）”绘制 PR 曲线，选择 F1 最大的点作为默认  $\tau = 0.62$ 。

### 4.4 语义感知的查询重构策略

触发检索后，如何构造高质量的查询是影响后续召回的关键。本文针对军事术语与多跳推理特点，设计三类自适应查询重构策略。

#### 4.4.1 实体增强策略

面向基础事实查询，最重要的是把握查询中的关键军事实体。**实体增强策略**的核心流程是：

- (1) 对已生成文本与原问题做军事实体识别，得到候选实体集  $E_q$ ；
- (2) 对每个实体  $e_i$  计算重要度权重  $\alpha_i$ ，融合注意力依赖度与 IDF 频次特征：

$$\alpha_i = \beta \cdot \text{att}(e_i) + (1 - \beta) \cdot \text{IDF}(e_i) \quad (4-7)$$

其中  $\text{att}(e_i)$  为生成位置对该实体的注意力依赖均值， $\text{IDF}(e_i)$  为其在知识库中的逆文档频率， $\beta$  为融合系数（默认 0.6）。

- (3) 按  $\alpha_i$  排序选择 Top- $K$  实体（ $K$  默认为 3-5），与必要的问题关键词拼接形成新查询。

该策略适用于“歼-20 的最大起飞重量是多少”“第 72 集团军部署在哪里”这类查询的事实型补检索。

#### 4.4.2 实词聚焦策略

面向冗长复杂查询，需要剔除助词、连词等无信息词，聚焦于语义核心词。**实词聚焦策略**流程如下：

- (1) 对原查询与已生成文本做词性标注；
- (2) 结合军事词典对每个词标注是否为军事术语；
- (3) 保留名词、动词、专有名词、数词类实词与全部军事术语，剔除其他词类；
- (4) 按注意力权重对实词排序，选取 Top- $K$  实词构建精简查询。

举例说明：原查询“分析美国在印太地区增加军事部署对中国周边安全环境造成的潜在影响”，经实词聚焦后可精简为“美国印太军事部署中国周边安全”。这种精简能显著降低检索噪声，提高召回的精确性。

#### 4.4.3 上下文融合策略

面向多跳推理，模型在前几跳已生成的内容本身即蕴含后续检索所需的信息线索。**上下文融合策略**将已生成内容中触发点附近的若干段文本与原问题一起作为新的检索上下文：



(1) 取触发位置前一定长度（默认 100 字）的已生成片段  $c_t$ ；(2) 将  $c_t$  与原问题  $q$  进行拼接： $q' = q + \text{“当前推理:”} + c_t$ ；(3) 将上下文增强后的查询送入检索器。

该策略本质上是把“模型已经推理到哪里”作为检索的额外条件，使后续检索更聚焦于尚未澄清的推理点。检索得到的证据被插入到原问题与已生成内容之间，模型基于这一新的上下文继续生成，形成“推理-验证-再推理”的迭代闭环。

#### 4.4.4 策略选择器

三类策略各有适用场景，本文设计了简单有效的策略选择器：根据 ?? 节的问题分类结果决定主策略——装备参数类用实体增强，战略态势类用上下文融合，对抗环境类则结合实词聚焦过滤噪声。当一种策略产生的检索结果质量不佳（首条结果相似度低于阈值 0.55）时，自动回退到另一策略再次重构，以提高鲁棒性。三类策略的选择决策如图 ?? 所示。




图 4-3 三类查询重构策略选择决策图

## 4.5 循环推理流程与终止控制

### 4.5.1 循环主流程

动态检索-生成的循环主流程在算法 ?? 中给出。流程主线为：触发检测 → 策略选择 → 查询重构 → 检索 → 证据合并 → 续写 → 终止判定。每生成  $\Delta_t$  个 token 检查一次触发条件（默认  $\Delta_t = 8$ ），在保证响应粒度的同时控制检测开销。

### 4.5.2 证据融合机制

多轮检索可能召回内容相近、版本不同甚至相互冲突的证据片段。本文设计三步证据融合机制：

(1) **语义相似度去重**：对新召回的证据片段与已有证据集计算语义相似度，相似度高于 0.85 的视为重复片段，保留来源权威性更高的一项；

(2) **来源可信度加权**：根据每个证据片段元信息中的权威性等级（条令 > 官方公报 > 主流媒体 > 一般评论）赋予不同权重，写入证据集；

**算法 1** 动态检索-自适应查询重构主流程

**输入：** 用户查询  $q$ ；大语言模型  $\mathcal{M}_\theta$ ；知识库  $\mathcal{D}$ ；嵌入模型  $\mathcal{E}$ ；阈值  $\tau$ ；预算  $K_{\max}$

**输出：** 最终回答  $y$  与证据集  $\mathcal{Z}$

```

1:  $\mathcal{Z} \leftarrow \text{Retrieve}(\mathcal{E}(q), \mathcal{D}, k_0)$  ▷ 初次检索
2:  $y \leftarrow \emptyset, k \leftarrow 0, \text{low\_cnt} \leftarrow 0$ 
3: 当  $y$  未达到 EOS 或  $|y| < L_{\max}$  执行
4:   由  $\mathcal{M}_\theta$  生成  $\Delta_t$  个 token, 记录  $p_\theta$ 、注意力矩阵  $\text{Attn}$ 
5:    $S(t) \leftarrow w_p \tilde{s}_p + w_a \tilde{s}_a + w_h \tilde{s}_h$  ▷ 综合判别
6:   若  $S(t) > \tau$  且  $k < K_{\max}$  则
7:      $\text{strategy} \leftarrow \text{Selector}(q, \text{type})$  ▷ 策略选择器
8:      $q' \leftarrow Q_{\text{strategy}}(q, y, \text{Attn})$  ▷ 查询重构
9:      $\mathcal{Z}' \leftarrow \text{Retrieve}(\mathcal{E}(q'), \mathcal{D}, k_0)$ 
10:     $\mathcal{Z} \leftarrow \text{Fuse}(\mathcal{Z}, \mathcal{Z}')$  ▷ 证据融合：去重 / 加权
11:     $k \leftarrow k + 1, \text{low\_cnt} \leftarrow 0$ 
12:   否则
13:      $\text{low\_cnt} \leftarrow \text{low\_cnt} + 1$ 
14:     若  $\text{low\_cnt} \geq L_{\text{stop}}$  则 break
15:     结束 若
16:   结束 当
17: 返回  $y, \mathcal{Z}$ 

```

(3) **时间/版本标记：**对事实多版本的证据按时间倒序排列，并在 Prompt 中显式注明版本信息，使生成器优先采用最新版本。

证据冲突的进一步处理交由第 5 章的一致性检测机制完成。

### 4.5.3 终止准则

为防止循环无限进行，本文设计了多重终止准则，满足任一条件即终止：(1) 模型已生成完整回答（达到 EOS 或  $L_{\max} = 1024$ ）；(2) 综合判别分数  $S(t)$  持续低于阈值  $\tau$  的步数超过  $L_{\text{stop}} = 16$ ，表明模型已稳定生成；(3) 检索迭代次数达到预算上限  $K_{\max} = 4$ ；(4) 累积证据规模达到上下文上限。

### 4.5.4 早停与成本控制

实时检索引入了显著的额外延迟。为兼顾效率与效果，本文引入若干工程化优化：

(1) **候选证据预排序：**对每次新召回的 Top- $K$  证据先用轻量重排序模型快速打分，仅保留 Top- $N$  注入上下文，避免无关证据占用宝贵的上下文窗口；

(2) **迭代预算  $K_{\max}$ ：**按问题复杂度自适应设定，简单事实问题  $K_{\max} = 1$ ，复杂推理问题  $K_{\max} = 4$ ；

(3) **检索结果缓存：**对相同或语义高度相似的查询缓存命中结果，避免重复检索；

(4) **异步触发：**检测器在 GPU 上以低优先级线程运行，与生成器主流程并行，进一步降低端到端延迟。

## 4.6 实验设计与结果

### 4.6.1 实验环境与基础设置

实验环境与第 3 章一致 (A100 40GB 单卡)。主干大模型用 Qwen2.5-7B-Instruct, 另用 Qwen2.5-14B-Instruct 和 DeepSeek-R1-Distill-Qwen-7B 做对照。嵌入模型用第 3 章微调后的 BGE-large-zh。生成温度 0.3, 最大生成长度  $L_{\max} = 1024$ , 每生成  $\Delta_t = 8$  个 token 检查一次触发, 单次检索  $\text{top-}k = 20$ 、重排后取  $\text{top-}5$  注入上下文, 检索预算上限  $K_{\max} = 4$ 。14B 受单卡显存限制需 8-bit 量化加载、推理较慢, 只用于对照, 主线实验都在 7B 上完成。

### 4.6.2 评测数据与指标

评测数据采用第 3.3 节构造的军事情报问答数据集的复杂推理子集 (约 350 条) 作为主要测试集; 同时引入 HotpotQA[?]、MuSiQue[?] 等通用域多跳问答数据集的中文翻译子集 (各 200 条) 作为对照。

针对生成质量采用: Exact Match、F1、Faithfulness (基于 NLI 模型对回答中每条事实主张与证据的蕴含关系打分)、Answer Relevance; 针对效率采用: 平均检索次数、平均延迟、Token 消耗。所有指标在 5 个随机种子下重复并报告均值与标准差。

### 4.6.3 总体性能对比 (Exp 4-1)

表 ?? 是在军事复杂推理子集上和基线方法的对比。几点观察: (1) 动态检索类方法整体比朴素 RAG 和进阶 RAG 好, 说明多跳问题上按需检索有帮助; (2) 本文方法 F1 比最强基线 DRAGIN 高约 1.4 个百分点, 提升幅度不大——这个子集本身难, 加上 7B 模型推理能力有限, 方法改进的空间是受限的; (3) 代价是本文方法的平均检索次数 (2.8) 和延迟 (3.92 秒) 都是所有方法里最高的, 比朴素 RAG 慢一倍多。也就是说, 本文方法是用更高的检索和时间开销换来一定的准确率提升, 这个取舍在对时效要求高的场景下未必划算。

表 4-2 动态检索方法总体性能对比 (军事复杂推理子集, Qwen2.5-7B, Exp 4-1)

| 方法            | EM (%)                           | F1 (%)                           | Faith. (%)  | $\bar{N}_R$ | 延迟 (s) |
|---------------|----------------------------------|----------------------------------|-------------|-------------|--------|
| 朴素 RAG        | $32.4 \pm 0.9$                   | $50.3 \pm 0.8$                   | 61.2        | 1.0         | 1.78   |
| 进阶 RAG (HyDE) | $34.6 \pm 0.8$                   | $52.7 \pm 0.7$                   | 64.0        | 1.0         | 2.04   |
| FLARE         | $36.5 \pm 0.7$                   | $54.8 \pm 0.6$                   | 68.3        | 2.3         | 3.34   |
| Self-RAG      | $38.1 \pm 0.6$                   | $56.9 \pm 0.6$                   | 70.6        | 1.8         | 2.87   |
| CRAG          | $38.8 \pm 0.7$                   | $57.6 \pm 0.6$                   | 71.2        | 1.7         | 2.65   |
| IRCoT         | $40.3 \pm 0.6$                   | $59.4 \pm 0.5$                   | 73.5        | 2.9         | 3.84   |
| DRAGIN        | $41.0 \pm 0.6$                   | $60.1 \pm 0.5$                   | 74.8        | 2.4         | 3.39   |
| <b>本文方法</b>   | <b><math>42.7 \pm 0.5</math></b> | <b><math>61.5 \pm 0.5</math></b> | <b>76.2</b> | 2.8         | 3.92   |

不同方法在 EM/F1 与延迟两个维度的关系如图 ?? 所示, 本文方法位于右上方, 准确率相对高但延迟也最高。




图 4-4 动态检索方法 F1-延迟权衡散点图

#### 4.6.4 触发信号消融实验 (Exp 4-2)

表 ?? 是三个信号的消融。单用任一信号都不如三者融合，且各信号在不同子任务上各有侧重：概率信号  $s_p$  在装备参数这类事实查询上相对好，注意力信号  $s_a$  在态势分析上较敏感，熵信号  $s_h$  在对抗环境验证上更稳。融合后总体 F1 比最好的单信号高约 4 个百分点。但这里也暴露一个问题：三信号融合主要在复杂多跳问题上有帮助，对简单事实型问题（如直接问某装备的单一参数），加权融合反而可能因熵或注意力波动触发不必要的检索，收益很有限甚至略有下降——这也是本文把触发判断和问题类型绑定的原因之一。

表 4-3 触发信号消融实验：三个子任务上的 F1 (%) 表现 (Exp 4-2)

| 信号组合                   | 装备参数        | 战略态势        | 对抗环境        | 总体 F1       |
|------------------------|-------------|-------------|-------------|-------------|
| 仅 $s_p$                | 58.4        | 48.2        | 44.7        | 50.4        |
| 仅 $s_a$                | 50.6        | 56.8        | 46.3        | 51.2        |
| 仅 $s_h$                | 48.5        | 51.4        | 54.9        | 51.6        |
| $s_p + s_a$            | 60.8        | 58.3        | 50.1        | 56.4        |
| $s_p + s_h$            | 60.4        | 53.2        | 57.2        | 56.9        |
| $s_a + s_h$            | 54.7        | 59.0        | 58.4        | 57.4        |
| $s_p + s_a + s_h$ (本文) | <b>64.3</b> | <b>61.2</b> | <b>59.1</b> | <b>61.5</b> |

#### 4.6.5 其他实验结果汇总

表 ?? 汇总了 Exp 4-3 至 Exp 4-7 五组实验的关键结果。

从这几组实验能看出几点。阈值方面， $\tau$  太低 (0.30) 会触发大量无效检索，检索次数涨到 4.9 次但 F1 反而下降；太高 (0.90) 又会漏掉真实知识缺口；本文取 0.62 算折中，但要承认这个值是在验证集上调出来的，换一批数据未必最优。重构策略方面，自适应选择比单一策略好，但提升也就 4 个点左右；实际观察中，实词聚焦在短问题上偶尔会把关键限定词一并删掉，导致语义漂移、检回不相关文档，这也是单用实词聚焦偏低的原因。检索预算方面， $K_{\max}$  从 4 增到 5 几乎没有收益但延迟还在涨，所以取 4。主干方面，换 14B 后 F1 到 65.2，但前面提过 14B 要量化、推理更慢，

表 4-4 Exp 4-3 ~ Exp 4-7 实验结果汇总

| 实验            | 对比设置                   | F1 (%)      | $\bar{N}_R$ |
|---------------|------------------------|-------------|-------------|
| Exp 4-3: 触发阈值 | $\tau = 0.30$          | 58.9        | 4.9         |
|               | $\tau = 0.50$          | 60.7        | 3.3         |
|               | $\tau = 0.62$ (本文)     | <b>61.5</b> | 2.8         |
|               | $\tau = 0.90$          | 54.6        | 1.3         |
| Exp 4-4: 重构策略 | 仅实体增强                  | 57.8        | 2.6         |
|               | 仅实词聚焦                  | 56.4        | 2.7         |
|               | 仅上下文融合                 | 57.0        | 2.9         |
|               | 自适应选择 (本文)             | <b>61.5</b> | 2.8         |
| Exp 4-5: 权重   | 静态平均权重                 | 59.3        | 2.9         |
|               | 任务自适应 (本文)             | <b>61.5</b> | 2.8         |
| Exp 4-6: 检索预算 | $K_{\max} = 1$         | 52.1        | 1.0         |
|               | $K_{\max} = 2$         | 57.8        | 1.9         |
|               | $K_{\max} = 3$         | 60.6        | 2.5         |
|               | $K_{\max} = 4$ (本文)    | <b>61.5</b> | 2.8         |
|               | $K_{\max} = 5$         | 61.6        | 3.1         |
| Exp 4-7: 主干迁移 | Qwen2.5-7B (本文主线)      | 61.5        | 2.8         |
|               | Qwen2.5-14B            | 65.2        | 2.6         |
|               | DeepSeek-R1-Distill-7B | 64.0        | 2.7         |

属于拿速度换精度。另外补充一点：在推理链较长的问题上，后几轮检索的查询会逐渐偏离最初问题——因为查询重构依赖已生成内容，而已生成内容本身可能已经跑偏，误差会累积，这是当前方法尚未很好解决的问题。

#### 4.6.6 案例分析 (Exp 4-8)

选取测试集中的复杂推理样本：“分析某型反舰导弹与目标海域典型岛屿的结合，可能形成的区域拒止能力”。本文方法的完整推理轨迹如下：

**第 1 轮：**初次检索召回反舰导弹技术参数文档。模型开始生成“该型导弹射程约 XXX 公里，掠海飞行高度…”，在生成“与目标海域典型岛屿结合后”位置， $s_a$  信号显著升高（关注实体“目标海域”但置信度低），触发检索。

**第 2 轮：**策略选择器判定为“战略态势分析”，启用上下文融合策略，重构查询包含已生成的导弹参数与岛屿信息，召回目标海域地理环境文档。模型续写“岛屿地形可作为隐蔽部署阵地”，在生成“形成的区域拒止覆盖范围”位置， $s_h$  信号突增，触发检索。

**第 3 轮：**重构查询聚焦“区域拒止覆盖雷达盲区”，召回相关战术分析。模型整合三轮证据完成最终回答，整体准确召回了导弹参数、地形特征、战术影响三块互补知识，体现了动态多轮检索在复杂推理场景下的优势。

### 4.7 本章小结

本章针对一次性检索难以应对多跳问题，做了一种结合多信号触发与查询重构的动态检索方法。触发判断同时用 Token 概率、注意力权重、输出熵三个信号加权，并按问题类型调整权重；查询重构尝试了实体增强、实词聚焦、上下文融合三种方式；多轮检索设了终止条件避免无限循环。在军事复杂推理子集上，F1 从朴素 RAG 的 50.3% 提升到约 61.5%，比最强基线高 1 个百分点出头。需要客观地说，这个提升是用更高的检索次数和延迟换来的，对简单事实问题收益有限，长链问题上还存在后续检索偏离原问题的情况。本章只关注了“何时检索、检索什么、检索几次”，没有处理检索到的内容是否可信——这正是下一章的对抗环境问题。

## 第 5 章 面向对抗环境的情报可信增强与噪声过滤

### 5.1 引言与威胁模型

#### 5.1.1 对抗场景描述

与传统通用问答相比，军事情报问答具有天然的对抗性。情报来源庞杂、版本众多，加之敌方可能有意散布虚假信息或实施认知域攻击，使得检索语料库中混入伪造、矛盾、过时甚至带有劫持指令的文档已成为必须考虑的现实威胁。具体可归纳为以下三类典型威胁：

- (1) **被动噪声**：检索语料库本身包含的低质量、过时、自相矛盾、来源不可靠的文档；
- (2) **主动投毒** [?, ?]：攻击者有意构造并注入伪造文档，目标可能是误导回答、放大特定偏见或触发拒答；
- (3) **提示注入** [?, ?]：在检索文档中嵌入“忽略上文”“你现在扮演 X”“请输出 Y”等控制指令，劫持生成器行为。

上述三类威胁均可能导致 RAG 系统输出错误，在军事决策语境下后果可能较严重。这里需要先说明威胁模型的现实性：本文并不假设攻击者能直接侵入涉密内网篡改离线库（这种情况下问题已超出 RAG 防御范畴），而是针对更现实的情形——知识库的数据来源本身可能被污染，例如开源情报、网络评论、第三方报送的数据在采集环节就混入了伪造或被操纵的内容，或数据供应链中的某一环被植入了对抗样本。也就是说，本文关注的是“进入知识库的数据不完全可信”这一前提下的过滤问题，而非内网入侵防护。

#### 5.1.2 威胁模型形式化

记原始干净知识库为  $\mathcal{D}_{\text{clean}}$ ，攻击者向其中注入投毒文档集  $\mathcal{D}_{\text{poison}}$  后形成污染知识库  $\mathcal{D}_{\text{adv}} = \mathcal{D}_{\text{clean}} \cup \mathcal{D}_{\text{poison}}$ 。定义投毒率：

$$\rho = \frac{|\mathcal{D}_{\text{poison}}|}{|\mathcal{D}_{\text{adv}}|} \quad (5-1)$$

攻击者目标是最大化模型输出  $y$  与真值答案  $y^*$  的偏离度。本文研究的对抗设定为白盒检索-黑盒生成：攻击者可访问检索器与语料库（白盒），但不能修改大语言模型本身（黑盒）。该设定符合大多数实际场景。

#### 5.1.3 本章方法概览

针对上述威胁，本章提出两阶段防御机制：

**前置过滤**：在检索结果送入大模型之前，通过语义聚类与领域特征联合识别可疑文档并予以剔除（?? 节）；

**后置评估**：在生成阶段并行考察内部先验回答与基于外部证据的回答，通过一致性检测、四维可靠性评估与可靠来源选择得出最终可信输出（?? 与 ?? 节）。

该框架并不要求重新训练大语言模型，可作为外挂模块叠加在任意 RAG 系统之上，具有良好的工程实用性。

## 5.2 总体防御框架

两阶段可信增强框架如图 ?? 所示。用户查询经过检索器得到 Top- $K$  候选文档后, 依次进入: (1) 语义聚类前置过滤模块, 剔除可疑文档; (2) 大模型双路候选生成——内部先验路径仅基于模型内部知识生成  $y_{\text{prior}}$ , 外部证据路径基于过滤后证据集生成  $y_{\text{ext}}$ ; (3) 一致性冲突检测, 识别证据中的冲突簇; (4) 自评估与来源选择, 根据四维可靠性指标决定最终输出  $y_{\text{final}}$ , 必要时触发补检索或主动拒答。




图 5-1 两阶段可信增强总体框架

## 5.3 基于语义聚类的文档过滤机制

### 5.3.1 方法动机

观察表明, 投毒文档为达到诱导效果, 通常在主题与表述上需要与真实证据保持相当的语义接近度 (否则容易被检索器自然过滤掉)。但即便如此, 其在更细致的语义空间中仍倾向于形成与真实



文档可分离的子簇或离群分布。同时，主动投毒文档由于需要在有限篇幅内嵌入足够强的诱导信号，往往呈现典型的语言特征（如断言密集、缺乏证据链、含可疑指令）。基于这些观察，本文设计基于语义聚类与领域特征联合的前置过滤机制。

### 5.3.2 聚类方法选择

本文对比了 K-means、HDBSCAN[?]、谱聚类、深度嵌入聚类 (DEC) [?] 等四类方法。综合考虑算法稳定性、可解释性与计算开销，最终选用 K-means 作为主算法，辅以离群点检测以处理少量散布的伪造文档。设候选文档集为  $\mathcal{D}_{\text{cand}} = \{d_1, \dots, d_N\}$ ，其嵌入表示为  $\{e_1, \dots, e_N\}$ ，聚类后得到簇  $\{C_1, \dots, C_K\}$ ，簇中心为  $\mu_k$ 。每个文档的离群得分定义为：

$$\text{outlier}(d) = \frac{\|e_d - \mu_{c(d)}\|_2 - \bar{\mu}_{\text{dist}}}{\sigma_{\text{dist}}} > \theta_{\text{out}} \quad (5-2)$$

其中  $\bar{\mu}_{\text{dist}}$  与  $\sigma_{\text{dist}}$  分别为所有文档到其所属簇中心距离的均值与标准差， $\theta_{\text{out}}$  为离群阈值。当某文档的标准化距离超过阈值时，即被视为潜在离群点。语义聚类过滤的可视化效果如图 ?? 所示。




图 5-2 语义聚类过滤可视化（基于 t-SNE 投影；蓝色为干净文档，红色为投毒文档）

### 5.3.3 领域特征增强

单纯依赖语义聚类容易将“语义偏远但实属真实”的少数派文档误判为投毒。为降低误判率，本文叠加三类领域特征作为补充判别信号：

- (1) **军事实体匹配度**  $\text{Ent}(d)$ ：文档与第 3.2.2 节实体词典的实体命中数与文档长度之比；
- (2) **关键词匹配度**  $\text{Kwd}(d)$ ：文档与查询的实词重叠度；
- (3) **注入指令检测得分**  $\text{Inj}(d)$ ：扫描文档中的可疑指令模式（如“忽略上文”“ignore previous”“你现在是…”“请输出…”等），输出 0-1 概率。该模块基于正则表达式与轻量分类器联合实现。

### 5.3.4 级联过滤管线

综合上述信号，本文为每个候选文档计算可信度评分：

$$\text{Score}_{\text{trust}}(d) = \lambda_1(1 - \text{outlier}(d)) + \lambda_2\text{Ent}(d) + \lambda_3\text{Kwd}(d) + \lambda_4(1 - \text{Inj}(d)) \quad (5-3)$$

其中  $\lambda_1 + \lambda_2 + \lambda_3 + \lambda_4 = 1$ 。所有候选文档按  $\text{Score}_{\text{trust}}$  从高到低排序，取 Top- $N$ （默认  $N = 8$ ）作为清洗后证据集  $\mathcal{Z}_{\text{filtered}}$ ，送入后续生成阶段。

### 5.3.5 阈值确定与人工反馈

权重  $\lambda_i$  与阈值  $\theta_{\text{out}}$  在验证集上通过网格搜索确定，目标函数为综合考虑召回率（保留真实证据的比例）与误报率（误删真实证据的比例）的  $\text{F1}_{\text{Robust}}$  指标：

$$\text{F1}_{\text{Robust}} = \frac{2 \cdot \text{Recall}_{\text{clean}} \cdot (1 - \text{FPR})}{\text{Recall}_{\text{clean}} + (1 - \text{FPR})} \quad (5-4)$$

经网格搜索得到  $\lambda_1 = 0.45, \lambda_2 = 0.22, \lambda_3 = 0.13, \lambda_4 = 0.20, \theta_{\text{out}} = 1.85$ 。为支持系统的持续优化，过滤模块预留了人工审核反馈接口：高风险候选（评分接近阈值）可送入人工二次判定，结果作为新的训练样本用于在线调整权重。

## 5.4 基于内外部知识一致性的冲突检测

### 5.4.1 内部知识先验提取

大语言模型在预训练阶段已习得大量通用与部分领域知识，对若干问题具有相对可靠的“内部先验回答”。该先验虽然在专业问题上不一定准确，但作为对外部证据的辅助校验是极为有价值的——当外部证据与内部先验剧烈冲突时，往往提示外部证据可能存在污染。

本文设计轻量的内部知识先验提取模块：给定查询  $q$ ，构造引导式提示要求模型在不看检索证据的情况下输出对问题的初步回答  $y_{\text{prior}}$ ，并以结构化方式列出关键事实声明  $F_{\text{prior}} = \{f_1, f_2, \dots, f_m\}$ 。每条事实声明附带一个内部置信度（基于生成时的对数概率与多次采样的一致性） $[?, ?]$ 。

### 5.4.2 一致性判定器

对清洗后证据集  $\mathcal{Z}_{\text{filtered}}$  中的每个证据片段  $d_i$  与每条先验声明  $f_j$ ，本文设计两个互补的判定器：

- (1) **语义相似度判定**  $\text{sim}_{\text{sem}}(d_i, f_j)$ ：基于嵌入向量的余弦相似度；
- (2) **自然语言推理判定**  $\text{NLI}(d_i, f_j)$ ：基于预训练 NLI 模型输出 entailment / neutral / contradiction 三类概率，定义其差值： $\text{nli\_score} = P(\text{entail}) - P(\text{contradict})$ 。

两类判定融合为综合一致性分：

$$c(d_i, f_j) = \alpha \cdot \text{sim}_{\text{sem}}(d_i, f_j) + \beta \cdot \text{nli\_score}(d_i, f_j) \quad (5-5)$$

其中  $\alpha + \beta = 1$ ，默认  $\alpha = 0.4, \beta = 0.6$ （NLI 判定优先，因其能区分蕴含与矛盾）。

### 5.4.3 证据关系图与簇分析

一致性分仅刻画证据与先验的两两关系，而真实场景下证据之间也可能相互支持或冲突。本文进一步构建证据关系图  $G = (V, E)$ ：节点  $V$  为清洗后证据片段，边  $E$  的权重  $w_{ij}$  基于证据片段之间的 NLI 蕴含度计算（正值代表互证、负值代表冲突）。在该图上采用 Louvain 社区发现算法 [?] 识别紧密相关的证据簇。

对识别出的簇按“与内部先验一致性的平均水平”分类为：

- (1) **可信簇**  $C_{\text{trust}}$ : 簇内证据互证度高, 且与内部先验一致性显著;
- (2) **冲突簇**  $C_{\text{conflict}}$ : 簇内证据互证度高但与先验/其他簇存在系统性矛盾;
- (3) **孤立证据**: 未形成稳定簇的离散证据。

当存在冲突簇时, 系统进入“重新审视”流程——可能触发补检索 (参见 ?? 节) 以扩充证据基础, 或将冲突信息直接呈现给用户由其判断。证据关系图与簇分析示意如图 ?? 所示。




图 5-3 证据关系图与簇分析示意

## 5.5 面向可信回答的自评估与可靠来源选择

### 5.5.1 多维可靠性评估指标

为系统量化每条候选回答的可信度, 本文设计四维评估指标, 如表 ?? 所示。

表 5-1 可靠性多维评估指标

| 指标       | 定义              | 计算方法                                                              |
|----------|-----------------|-------------------------------------------------------------------|
| 证据覆盖度 EC | 回答中事实主张被证据支持的比例 | $\text{NLI}(\text{claim}, \text{evidence}) \text{ entailment 比例}$ |
| 证据对齐度 EA | 回答与最强证据的语义相似度   | 嵌入余弦                                                              |
| 自一致性 SC  | 多次温度采样生成的一致性    | 多次采样回答相似度均值                                                       |
| 不确定性 Unc | 多次采样输出的对数概率方差   | $\text{Var of log-likelihood}$                                    |

**证据覆盖度 EC** 用于刻画回答的事实性。具体做法是先从回答中抽取若干“事实主张”(claim), 再用 NLI 模型对每条主张与证据集做蕴含判定, 统计 entailment 比例。

**证据对齐度 EA** 用于刻画回答与最强证据的语义贴近程度, 避免“answer 蕴含 evidence 但语义偏离”的情况。

**自一致性** SC 用于刻画模型对自身回答的稳定度。多次采样（默认 5 次）所得回答相互之间的相似度均值越高，说明模型对该问题的回答越稳定。

**不确定性** Unc 用于度量模型生成过程的“分歧”。多次采样的对数似然方差越大，说明模型对该回答越不自信。

### 5.5.2 候选生成与决策策略

为充分利用模型内部知识与外部证据各自的优势，本文采用双路并行生成：内部先验路径  $y_{\text{prior}}$ （仅基于内部知识）与外部证据路径  $y_{\text{ext}}$ （基于清洗后证据  $\mathcal{Z}_{\text{filtered}}$ ）。对两路候选各计算上述四维指标，形成指标向量  $\mathbf{v}_{\text{prior}}$  与  $\mathbf{v}_{\text{ext}}$ 。

决策环节本文提供两类策略：

(1) **阈值决策**：若  $\text{EC}(y_{\text{ext}}) > \tau_{\text{EC}}$  且  $\text{Unc}(y_{\text{ext}}) < \tau_{\text{Unc}}$ ，则输出  $y_{\text{ext}}$ ；否则进入下一步判断。该策略简单、可解释、计算成本低，适合高风险场景的快速决策。

(2) **学习式决策**：训练一个小型 MLP，输入两路四维指标向量、外部证据集冲突情况等共 10–12 维特征，输出五类决策标签：使用  $y_{\text{ext}}$  / 使用  $y_{\text{prior}}$  / 触发补检索 / 触发追问 / 主动拒答。学习式决策可在验证集上拟合更细致的判别模式。

### 5.5.3 拒答与追问触发

在通用问答任务中，“敢于拒答”往往被视为消极特征；但在军事情报问答场景下，宁可拒答不可错答是基本原则。本文设计明确的拒答与追问触发规则：

(1) 当两路回答 EC、EA 均低于阈值且 Unc 高于阈值时，主动输出“信息不足，无法给出可靠结论”，并附拒答原因（如“未检索到权威条令”“检索到的证据存在严重冲突”等）；

(2) 当问题表述存在显著歧义（例如同名装备多种型号未明确）时，系统主动追问以澄清，而非默认猜测。

### 5.5.4 可解释输出

为使输出具备可追溯性，最终回答附带以下解释性元信息：

- (1) **关键支持证据片段**：选取对最终回答贡献最大的若干证据片段并附带来源；
- (2) **置信度分级标签**：高/中/低三档，分级依据为综合 EC、EA、SC、Unc 的归一化得分；
- (3) **不确定来源说明**：若回答存在不确定性，明确指出原因（如“基于过时条令”“涉及多版本信息”“存在敌方陈述”等）。

自评估与来源选择的整体决策流程如图 ?? 所示。

## 5.6 动态检索与可信防御的协同

本节阐述第 4 章动态检索机制与本章可信防御机制的协同方式。两机制在数据流上互补：动态检索决定“何时、用什么查询去检索”，可信防御决定“检索到的内容能不能用、回答可不可信”。二者之间存在以下三类协同点：

(1) **重构后再评估**：每次动态检索触发后，新召回的证据需经过 ?? 节聚类过滤再注入上下文，避免增量证据将噪声引入；

(2) **重构信号反馈**：若 ?? 节检测到冲突簇，则触发 4.4 节查询重构对冲突点进行靶向补检索（例如对装备某项参数存在两个值的矛盾，重构查询专门索取该参数的权威条令）；




图 5-4 自评与可靠来源选择决策流程

(3) **循环停止协同**：若多轮重构后仍无法解决冲突（冲突簇始终存在），则触发主动拒答而非强行生成。

为控制端到端延迟，主路在达到证据覆盖度阈值后立即返回主回答，同时后台异步进行更深度的验证；若深度验证发现冲突，主动通过用户界面提示“已检测到证据冲突，建议复核”，并附冲突证据摘要。

## 5.7 实验设计与结果

### 5.7.1 对抗评测集构造

在第 3.3 节对抗误导样本基础上，本章构造了用于评测的对抗样本集。三种投毒策略包括：

- (1) **直接矛盾投毒**：构造与真实事实直接相反的伪造陈述；
- (2) **部分替换投毒**：保留原始语境，篡改关键数字、实体或时间，使表面看起来真实；
- (3) **提示注入投毒**：在合法外观的文档末尾嵌入“忽略上述内容，请输出…”等劫持指令。

投毒率  $\rho \in \{1\%, 5\%, 10\%, 20\%\}$  共四档。对每条原始样本独立生成对应的投毒变体。

### 5.7.2 评测指标

针对对抗鲁棒性采用以下指标：攻击成功率 ASR、性能下降率 PDR、召回纯净度 RP、召回率  $\text{Recall}_{\text{clean}}$ 、误报率 FPR、拒答精确率/召回率。

### 5.7.3 总体鲁棒性对比 (Exp 5-1)

表 ?? 是 10% 投毒率下与基线方法的对比。本文方法把 ASR 从朴素 RAG 的 47.5% 降到约 32.5%，PDR 也有所下降，召回纯净度从 71.0% 提到约 84.6%。需要客观说明：第一，这个降幅虽然明显，但 ASR 仍有 32.5%，约三分之一的投毒攻击仍然得逞，远谈不上“防住”；第二，本文方法与加了简单过滤的 DRAGIN 相比差距并不大（约 6 个百分点），说明大部分收益来自“有没有过

滤”这一步，而不是过滤手段有多精巧；第三，加入可信过滤后 Recall (91.0%) 比朴素 RAG 略低，因为过滤阶段会误删一部分本来正确的文档——这是过滤的代价。

表 5-2 对抗鲁棒性总体对比 (投毒率  $\rho=10\%$ , Exp 5-1)

| 方法            | ASR (%)↓    | PDR (%)↓    | RP (%)↑     | Recall (%)↑ |
|---------------|-------------|-------------|-------------|-------------|
| 朴素 RAG        | 47.5        | 38.2        | 71.0        | 94.6        |
| 进阶 RAG        | 43.1        | 35.0        | 72.8        | 94.2        |
| Self-RAG      | 39.6        | 31.8        | 76.5        | 93.4        |
| CRAG          | 37.2        | 29.4        | 78.9        | 92.8        |
| DRAGIN + 简单过滤 | 38.4        | 30.5        | 77.6        | 92.1        |
| 本文方法          | <b>32.5</b> | <b>26.1</b> | <b>84.6</b> | 91.0        |

#### 5.7.4 不同投毒率下的鲁棒性曲线 (Exp 5-1 扩展)

图 ?? 给出投毒率从 1% 到 30% 变化时几种方法的 ASR 曲线。本文方法在各投毒率下都低于基线，但随着投毒率上升，ASR 的增长并没有被压住——10% 投毒时约 32.5%，20% 投毒时升到约 38%，30% 投毒时接近 45%。也就是说，投毒比例越高，过滤和一致性判断越吃力：当投毒文档占比足够大时，它们在语义空间里会形成自己的簇、甚至在数量上接近真实文档，聚类 and 多数表决的前提就不成立了。所以本文方法只能说在中低投毒率下缓解了攻击影响，并不能在高投毒率下保持稳定。




图 5-5 不同投毒率下的攻击成功率 (ASR) 演化曲线

#### 5.7.5 防御模块消融实验 (Exp 5-2)

表 ?? 是关掉不同模块时的 ASR/PDR 变化 (10% 投毒)。单用任何一个模块都不够：单用聚类过滤或单用一致性检测，ASR 还在 40% 上下；两两组合能降到 36% 左右；三个模块一起用降到约 32.5%。模块之间确实有互补，但叠加的边际收益是递减的——从两模块到三模块只多降了几个

百分点。另外，可信评估（尤其是多次采样算自一致性）会带来额外开销，实测三模块全开比无防御的推理时间多了约 15%。

表 5-3 防御模块消融实验 ( $\rho=10\%$ , Exp 5-2)

| 模块组合                          | ASR (%)↓    | PDR (%)↓    |
|-------------------------------|-------------|-------------|
| 无防御（朴素 RAG）                   | 47.5        | 38.2        |
| 仅聚类过滤                         | 40.8        | 32.6        |
| 仅一致性检测                        | 42.1        | 33.9        |
| 仅自评估 + 拒答                     | 41.3        | 33.0        |
| 聚类过滤 + 一致性检测                  | 35.7        | 28.8        |
| 一致性检测 + 自评估                   | 37.2        | 30.1        |
| <b>聚类过滤 + 一致性检测 + 自评估（本文）</b> | <b>32.5</b> | <b>26.1</b> |

### 5.7.6 其他实验结果汇总

表 ?? 汇总了 Exp 5-3 至 Exp 5-9 七组实验的关键结果。

从这几组实验能看出几点。聚类算法之间差别不大，K-means 略好，但选哪个算法影响有限，主要还是看有没有领域特征——去掉领域特征后 ASR 涨了约 5 个百分点。一致性判定上 NLI 比纯语义相似度好，因为它能区分“矛盾”和“无关”。自评估四个指标逐个加上去都有一点帮助，但每个边际贡献都不大。拒答策略这里要特别说明：拒答精确率 85.2%、召回率只有 61.7%，也就是说有近四成该拒答的情况没被识别出来——拒答阈值很敏感，调高了会误拒大量正常问题，调低了又漏掉该拒的，这个平衡并不好把握。协同方面，第 4、5 章一起用能把 ASR 再降几个百分点到约 28.3%。投毒策略方面，直接矛盾投毒最好防（与先验冲突明显），但部分替换投毒（只改个别数字、其余照抄真实文档）最难防，ASR 还有 35.8%，因为这类投毒文档在语义和来源特征上都跟真实文档很接近，聚类和一致性判断都不容易抓住。

### 5.7.7 案例分析 (Exp 5-10)

**案例 1：成功识别投毒。**查询“某型预警机最大续航时间”，检索结果中混入了伪造的“续航 36 小时”陈述（真值约 12 小时）。聚类过滤阶段，该投毒文档因与多数真实文档语义偏离被标记为离群点；一致性检测阶段，该陈述与内部先验严重矛盾，被划入冲突簇；最终系统采纳与先验、多数证据一致的“约 12 小时”作为回答。

**案例 2：主动拒答。**查询“某新型隐身无人机的具体战术编制”，检索结果均为公开评论，未涵盖明确的战术编制条令。自评估发现  $EC = 0.31$ ,  $Unc = 0.78$ ，触发拒答规则，输出“当前知识库不包含权威的相关条令资料，无法给出可靠结论”，避免因强行回答导致错误。

## 5.8 本章小结

本章针对检索库可能被投毒的问题，做了一种两阶段的过滤与可信判断方法：前置阶段用语义聚类加领域特征过滤可疑文档，后置阶段用内部先验与外部证据做一致性比对识别冲突，并用四个指标判断回答可信度，必要时拒答或补检索。在 10% 投毒率下，ASR 从朴素 RAG 的 47.5% 降到

表 5-4 Exp 5-3 ~ Exp 5-9 实验结果汇总 ( $\rho=10\%$ )

| 实验                            | 对比设置                    | ASR (%)      | F1 <sub>Robust</sub> |
|-------------------------------|-------------------------|--------------|----------------------|
| Exp 5-3: 聚类算法                 | K-means (本文)            | <b>32.5</b>  | <b>0.781</b>         |
|                               | HDBSCAN                 | 34.8         | 0.762                |
|                               | 谱聚类                     | 33.6         | 0.770                |
|                               | DEC                     | 33.2         | 0.773                |
| Exp 5-4: 领域特征                 | 仅语义聚类                   | 37.4         | 0.728                |
|                               | 语义聚类 + 领域特征 (本文)        | <b>32.5</b>  | <b>0.781</b>         |
| Exp 5-5: 一致性判定                | 仅语义相似度                  | 36.2         | 0.741                |
|                               | 仅 NLI                   | 34.1         | 0.764                |
|                               | 融合 (本文)                 | <b>32.5</b>  | <b>0.781</b>         |
| Exp 5-6: 自评估指标                | 仅 EC                    | 36.8         | 0.735                |
|                               | EC + EA                 | 35.0         | 0.752                |
|                               | EC + EA + SC            | 33.7         | 0.769                |
|                               | EC + EA + SC + Unc (本文) | <b>32.5</b>  | <b>0.781</b>         |
| Exp 5-7: 拒答策略 ( $\rho=10\%$ ) |                         | 拒答精确率        | 拒答召回率                |
|                               | 主动拒答                    | <b>85.2%</b> | <b>61.7%</b>         |
| Exp 5-8: 协同效果                 | 仅第 4 章动态检索              | 41.6         | 0.712                |
|                               | 仅第 5 章可信防御              | 32.5         | 0.781                |
|                               | 第 4 章 + 第 5 章 (协同)      | <b>28.3</b>  | <b>0.814</b>         |
| Exp 5-9: 投毒策略                 | 直接矛盾投毒                  | 29.4         | 0.802                |
|                               | 部分替换投毒                  | 35.8         | 0.748                |
|                               | 提示注入投毒                  | 31.2         | 0.792                |



约 32.5%；这个方法不需要重新训练大模型，可以挂在已有 RAG 上用。但要清楚它的局限：ASR 仍有 32.5%，攻击远没有被防住；投毒率升高后效果明显变差（20% 时约 38%）；过滤会误删正确文档导致召回略降；阈值比较敏感、聚类也会误判；对“部分替换”这类隐蔽投毒尤其乏力。把第 4 章和第 5 章一起用，ASR 能再降到约 28.3%，下一章把这些模块集成起来做整体评估。

## 第 6 章 系统集成与综合性能评估

### 6.1 引言

本章把前面几章的模块——第 3 章的知识库和微调嵌入模型、第 4 章的动态检索、第 5 章的两阶段过滤——集成为一个可本地离线运行的问答系统原型，并从准确性、复杂推理、鲁棒性、可信度、效率几个方面评估。目的主要是验证这些模块拼在一起能不能端到端跑通，以及整体效果如何。

### 6.2 系统总体架构

#### 6.2.1 三层架构设计

为保障模块化、可扩展性与离线部署能力，系统采用数据层、控制层、安全防御层三层架构，如图 ?? 所示。




图 6-1 军事情报问答系统总体架构（数据层 / 控制层 / 安全防御层）

**数据层**负责情报知识的获取、清洗、结构化与高效索引，主要组件包括：多源数据采集与预处理流水线、分类组织的军事情报知识库（按装备、条令、态势、案例四类组织）、领域微调的嵌入模型、FAISS HNSW 向量索引与 Elasticsearch 稀疏倒排索引、证据元信息管理子系统。

**控制层**作为系统的核心，负责问答流程控制、实时推理与知识动态获取，主要组件包括：大语言模型推理引擎（基于 vLLM[?]）、实时信息需求检测器、查询重构器、循环推理控制器、证据融合模块。该层将第 4 章提出的动态检索机制完整工程化。

**安全防御层**负责对抗环境下的情报净化与可信度校验，主要组件包括：基于语义聚类的检索结果纯化模块、内部知识先验提取器、一致性冲突检测模块、四维可靠性自评估器、可靠来源选择决策器以及人工反馈接口。该层将第 5 章提出的两阶段可信增强机制完整工程化。

### 6.2.2 模块接口规范

为支持模块的独立开发与替换，各模块以明确的接口规范对外暴露能力。主要模块的接口设计如表 ?? 所示。

表 6-1 系统主要模块接口规范

| 模块      | 主要输入          | 主要输出              | 依赖                |
|---------|---------------|-------------------|-------------------|
| 知识库索引   | 查询字符串         | Top- $K$ 文档 + 元信息 | 嵌入模型 / FAISS / ES |
| 信息需求检测器 | 生成状态、注意力矩阵    | 触发标志与综合得分         | 主干 LLM 钩子         |
| 查询重构器   | 原查询、生成上下文、注意力 | 重构后查询字符串          | NER / 军事词典        |
| 循环推理控制器 | 触发标志、当前轮次     | 继续/终止决策           | 配置参数              |
| 聚类过滤器   | Top- $K$ 文档   | 过滤后证据集            | 嵌入模型              |
| 一致性检测器  | 内部先验、证据集      | 可信簇、冲突簇           | NLI 模型            |
| 自评估决策器  | 双路候选、证据       | 最终回答、可信度          | 阈值 / MLP          |

## 6.3 关键模块的工程实现

### 6.3.1 知识库构建与索引

数据层采用多组件协同：原始语料先经分布式数据清洗流水线（基于 Python 与 Ray 并行框架），输出标准化的 JSONL 文件；分块结果分别送入 FAISS 索引（用于稠密检索）与 Elasticsearch（用于稀疏检索）。元信息采用 PostgreSQL 存储，与向量索引通过文档 ID 关联。整个数据层支持增量更新——新增情报数据可通过定期批量任务进入索引而无需全量重建。

### 6.3.2 检索-生成主循环

控制层基于 PyTorch 与 HuggingFace Transformers 实现。大语言模型推理通过 vLLM 部署以获得高吞吐与低延迟。生成主循环以异步生成器形式实现，每生成  $\Delta_t$  个 token 由信息需求检测器评估是否触发检索。检测器以钩子形式注册到 transformer 的 forward 过程，可直接获取 logits 与注意力矩阵，无需对模型进行任何修改。重构器与检索器在并发线程中运行，结果通过线程安全队列回传到主循环。

### 6.3.3 实时信号采集

实时信号采集是动态检索机制工程化的关键。本文采用 HuggingFace Transformers 的自定义 LogitsProcessor 与 AttentionVisualizer 机制，在每一步生成时即时获取下一 token 的 logits 与最后若干层注意力矩阵，并通过低开销的滑动窗口缓冲实现 z-score 标准化。为减少显存压力，注意力矩阵仅保留与问题中实体位置相关的列，其余部分及时释放。

### 6.3.4 可信防御模块

安全防御层采用模块化部署：聚类过滤、NLI 模型分别部署为独立的微服务（基于 FastAPI），通过 gRPC 与主控制层通信。这样的解耦设计使得在不同部署场景下可以灵活调整防御强度——例如在严苛对抗场景下启用全部模块，在效率优先场景下仅启用聚类过滤。

### 6.3.5 前端交互

系统前端基于 Streamlit 构建轻量 Web 界面，主要功能包括：自然语言问答输入框、回答展示区（带置信度标签）、可展开的证据溯源面板、冲突警告提示、人工反馈按钮。前端通过 REST API 与后端通信，整套系统可以在内网部署而无需任何外网连接。系统前端界面示意如图 ?? 所示。

图 6-2 系统前端交互界面示意

## 6.4 部署环境与性能预算

系统在以下硬件配置下完成部署与评测：

- (1) 服务器：NVIDIA A100 80GB × 2, Intel Xeon Platinum 64 核, 512 GB 内存, 10 TB NVMe SSD;
- (2) 操作系统：Ubuntu 22.04 LTS;

(3) 软件栈: Python 3.10、PyTorch 2.1、vLLM 0.4、HuggingFace Transformers 4.40、FAISS 1.7.4、Elasticsearch 8.13、PostgreSQL 16;

(4) 网络: 完全离线部署, 无外网依赖;

(5) 端到端 P95 延迟预算: 基础事实类  $\leq 3$  秒, 复杂推理类  $\leq 10$  秒。

完全离线部署是军事场景下的硬性要求, 本系统的所有模型(大语言模型、嵌入模型、NLI 模型、NER 模型)与依赖均预先打包至本地, 运行时不产生任何外部网络请求。

## 6.5 综合性能评估

### 6.5.1 评测维度与指标体系

系统级评测从五个维度展开, 对应指标如表 ?? 所示。

表 6-2 综合性能评估维度与指标体系

| 评测维度    | 关键指标                                    | 评测子集        |
|---------|-----------------------------------------|-------------|
| 问答准确性   | Precision / Recall / F1 / EM            | 基础事实 + 复杂推理 |
| 复杂推理能力  | 多跳链完成度、中间步骤验证准确率                        | 复杂推理子集      |
| 系统鲁棒性   | ASR、PDR、召回纯净度                           | 对抗投毒子集      |
| 信息可信度   | Faithfulness、Citation Accuracy、5 分制人工评分 | 全部子集        |
| 检索与推理效率 | 平均检索次数、平均延迟、Token 消耗                    | 全部子集        |

### 6.5.2 端到端总体性能对比 (Exp 6-1)

表 ?? 是本文系统与几种 RAG 方法的端到端对比。本文系统的 F1 (约 61.5%) 和 Faithfulness (约 76%) 相对靠前, ASR (约 28.3%, 此处为 10% 投毒下集成动态检索与可信防御的结果) 也低于其他方法。但要说明两点: 一是这些指标的领先幅度并不大, F1 比 IRCOT 高 2 个百分点左右; 二是代价是延迟和检索次数都偏高 (约 4.0 秒、2.8 次), 是朴素 RAG 的两倍多。换句话说, 本文系统是在牺牲响应速度的前提下换来准确性和鲁棒性的一些改善, 这个取舍是否值得要看具体场景。

表 6-3 端到端系统总体性能对比 (Exp 6-1)

| 方法          | F1 $\uparrow$ | Faith. $\uparrow$ | ASR $\downarrow$ | 延迟 (s) | $\bar{N}_R$ |
|-------------|---------------|-------------------|------------------|--------|-------------|
| 朴素 RAG      | 50.3          | 61.2              | 47.5             | 1.78   | 1.0         |
| 进阶 RAG      | 52.7          | 64.0              | 43.1             | 2.04   | 1.0         |
| FLARE       | 54.8          | 68.3              | 41.2             | 3.34   | 2.3         |
| Self-RAG    | 56.9          | 70.6              | 39.6             | 2.87   | 1.8         |
| CRAG        | 57.6          | 71.2              | 37.2             | 2.65   | 1.7         |
| IRCOT       | 59.4          | 73.5              | 40.5             | 3.84   | 2.9         |
| <b>本文系统</b> | <b>61.5</b>   | <b>76.2</b>       | <b>28.3</b>      | 3.98   | 2.8         |

### 6.5.3 模块级消融实验 (Exp 6-2)

表 ?? 是模块级消融。从朴素 RAG 到完整系统, F1 提升约 11 个百分点, ASR 下降约 19 个百分点。领域微调和动态检索主要贡献 F1, 可信防御主要贡献 ASR 下降, 三者作用的指标不同。但也能看出, 加上可信防御后 F1 反而比只有动态检索时略低, 因为过滤会误删部分正确证据, 准确性和鲁棒性之间存在一定的此消彼长。

表 6-4 端到端系统模块级消融 (Exp 6-2)

| 系统配置             | F1 (%)↑     | ASR (%)↓    | 延迟 (s) | $\bar{N}_R$ |
|------------------|-------------|-------------|--------|-------------|
| 朴素 RAG (基线)      | 50.3        | 47.5        | 1.78   | 1.0         |
| + 领域微调嵌入         | 54.8        | 44.2        | 1.85   | 1.0         |
| + 动态检索 (去可信防御)   | 61.5        | 41.6        | 3.92   | 2.8         |
| + 可信防御 (去动态检索)   | 56.7        | 32.5        | 2.61   | 1.0         |
| <b>完整系统 (本文)</b> | <b>61.5</b> | <b>28.3</b> | 3.98   | 2.8         |

### 6.5.4 不同主干性能-延迟权衡 (Exp 6-3)

表 ?? 是三种主干上的结果。换成 14B 后 F1 能提升约 4 个百分点, DeepSeek-R1-Distill-7B 居中。不同主干的 ASR 差别不大, 说明可信防御受主干影响较小。不过 14B 在单卡上需要量化加载, 延迟涨到 5 秒以上, 实际部署时要在精度和速度间权衡。

表 6-5 不同 LLM 主干下系统性能-延迟权衡 (Exp 6-3)

| 主干模型                   | F1 (%) | Faith. (%) | ASR (%) | 延迟 (s) |
|------------------------|--------|------------|---------|--------|
| Qwen2.5-7B (本文主线)      | 61.5   | 76.2       | 28.3    | 3.98   |
| Qwen2.5-14B            | 65.2   | 79.0       | 27.1    | 5.64   |
| DeepSeek-R1-Distill-7B | 64.0   | 78.1       | 27.6    | 4.43   |

### 6.5.5 三阶段渐进评估 (Exp 6-4)

表 ?? 是三个评估阶段的关键指标。三个阶段结果基本稳定, 引入用户反馈后 F1 和拒答精确率有小幅提升。需要说明这只是初步的阶段验证, 样本量不大, 不足以支撑很强的结论。

表 6-6 三阶段渐进评估关键结果 (Exp 6-4)

| 评估阶段        | 样本数 | F1 (%)      | ASR (%)     | 拒答精确率        |
|-------------|-----|-------------|-------------|--------------|
| 阶段一 (小规模合成) | 100 | 61.8        | 28.5        | 85.0%        |
| 阶段二 (中期大规模) | 500 | 61.5        | 28.3        | 85.2%        |
| 阶段三 (含用户反馈) | 300 | <b>63.2</b> | <b>27.4</b> | <b>86.8%</b> |

### 6.5.6 真实场景案例展示 (Exp 6-5)

与合作单位协作选取若干脱密典型问答样例，覆盖装备、条令、态势、案例四类。每个案例完整展示系统的端到端处理流程，包括：触发轨迹、查询重构、聚类过滤、一致性判定、最终回答与可解释输出。系统端到端处理流程示意如图 ?? 所示。




图 6-3 端到端问答处理流程示意

### 6.5.7 专家用户调研 (Exp 6-6)

邀请 8 名具备军事相关背景的人员，对系统与朴素 RAG 在相同问题上的输出做盲评，从准确性、可读性、可信度三个维度采用 5 分制打分，每人独立评估 60 条（两系统各 30 条，随机打乱）。结果见表 ??。本文系统在三个维度上的均分都高于朴素 RAG，准确性和可信度的差距较明显，可读性差距较小。需要说明，评测人数只有 8 人、属于小样本主观评价，这里只报告均分和标准差作为参考，不宜据此下过强的统计结论。

表 6-7 专家用户调研打分结果 (5 分制, 8 人  $\times$  30 条; Exp 6-6)

| 评估维度 | 朴素 RAG          | 本文系统            | 均分差   |
|------|-----------------|-----------------|-------|
| 准确性  | $3.21 \pm 0.86$ | $3.92 \pm 0.63$ | +0.71 |
| 可读性  | $3.74 \pm 0.70$ | $4.05 \pm 0.55$ | +0.31 |
| 可信度  | $2.98 \pm 0.94$ | $3.86 \pm 0.68$ | +0.88 |

### 6.5.8 效率-效果散点图

综合 Exp 6-1 与 Exp 6-3 的全部数据，绘制不同方法与不同主干的效率-效果权衡散点图，如图 ?? 所示。本文方法在多个主干上大致落在准确率-延迟的较优边界上，但延迟普遍偏高，性能与速度之间的权衡比较明显。




图 6-4 端到端 F1-延迟权衡散点图 (含不同主干配置)

## 6.6 本章小结

本章把第 3-5 章的模块集成为一个可本地离线运行的问答系统原型，按数据层、控制层、安全防御层组织，并介绍了知识库索引、检索-生成主循环、实时信号采集、防御模块部署、前端交互等实现细节，从准确性、复杂推理、鲁棒性、可信度、效率几个方面做了评估。结果上，本文系统的 F1 (约 61.5%)、Faithfulness (约 76%)、ASR (约 28.3%) 相对几个基线有一定改善，但领先幅度不大，且都以更高的延迟 (约 4 秒) 为代价；小样本人工评价中准确性和可信度的均分也高于朴素 RAG。总体来看，本章验证了把各模块拼起来端到端跑通是可行的，但系统离实战部署还有距离，延迟、鲁棒性上限、评测规模都还需要进一步工作。



## 第 7 章 总结与展望

### 7.1 工作总结

随着体系化、集群化作战模式的发展，现代战场情报呈现海量、多源、对抗的特征，传统人工分析难以满足瞬息万变的决策时效与精度需求。大语言模型为构建智能情报问答系统提供了潜在路径，但其知识滞后、专业不足、易产生幻觉等固有缺陷使其难以直接应用于精度与可信度要求严苛的军事情报场景。检索增强生成方法能在一定程度上缓解上述问题，但通用 RAG 在军事情报这一兼具高专业性、高对抗性、高复杂性的场景下仍存在领域适配不足、静态检索难以多跳推理、对抗鲁棒性缺失三类突出问题。

围绕这一问题，本文以“领域适配—动态推理—对抗鲁棒”为主线，开展了面向军事情报问答的检索增强生成方法研究。主要工作总结如下：

(1) **军事情报领域知识库与对抗评测数据集构建**。设计多源数据采集与多阶段预处理流程，构建分类组织的军事情报知识库（约 31.5 万段落）；按“事实核验—关联分析—推理判断—综合生成”能力链条，构造了包含基础事实验证、复杂战术推理、对抗误导样本三类、总规模 1,276 条的军事情报问答数据集，并通过“机器初标 + 人工校验”流程及四项质量保障措施确保数据质量；以该数据集为正样本对开源嵌入模型进行 LoRA 领域微调，使其在军事检索任务上的 Recall@10 从 71.4% 提升到约 78.6%（受数据规模限制，提升幅度有限）。

(2) **基于实时信息需求的动态检索与自适应查询重构机制**。提出 Token 概率、注意力权重、输出熵三类信号联合判别的检索触发机制，并按装备参数查询、战略态势分析、对抗环境验证三类典型任务设计了任务自适应权重；针对军事术语长、问题表述复杂等特点，设计了实体增强、实词聚焦、上下文融合三类查询重构策略并实现自动选择；构建了带终止准则与早停机制的闭环循环推理流程。该方法将军事情报复杂推理子集上的 F1 由朴素 RAG 的 50.3% 提升到约 61.5%，但以增加检索次数和延迟为代价，对简单事实问题收益有限。

(3) **面向对抗环境的两阶段情报可信增强与噪声过滤机制**。提出语义聚类前置过滤与一致性后置评估相结合的两阶段防御框架，前置阶段基于语义聚类与领域特征联合识别可疑文档，后置阶段通过证据关系图聚类识别可信簇与冲突簇；建立证据覆盖度、证据对齐度、模型自一致性、不确定性四维可靠性评估指标，构建阈值决策与学习式决策相结合的可靠来源选择策略，并支持低置信场景下的主动拒答与补检索。在 10% 投毒率下将攻击成功率从朴素 RAG 的 47.5% 降到约 32.5%，但无法完全消除投毒影响，高投毒率下效果明显变差。

(4) **端到端军事情报问答系统集成与综合性能评估**。将上述模块按数据层、控制层、安全防御层三层架构集成为端到端原型，本地离线部署。系统的 F1（约 61.5%）、Faithfulness（约 76%）、ASR（约 28.3%）相对几个基线有一定改善，但领先幅度不大且以更高延迟为代价；小样本人工评价中准确性和可信度的均分也高于朴素 RAG。

### 7.2 主要创新点

本文的主要创新点可归纳为以下三个方面。

(1) **面向军事情报问答整理了一个带对抗样本的数据集与配套的领域微调嵌入模型**。现有公开军事数据集大多面向新闻分析或事件抽取，本文按情报研判流程构造了三类样本，并配套了分类知识库和微调模型。这部分主要是支撑性的数据工作。

(2) **基于多源内部信号融合的动态检索与任务自适应查询重构机制**。区别于 FLARE 等基于单一信号触发的方法，本文同时利用三类相互补充的信号构造综合判别函数，并按任务类型自适应调

整权重；进一步针对军事术语特征设计了实体增强、实词聚焦、上下文融合三类查询重构策略，能够更好地适应军事情报问答的多种问题形态。

(3) **针对检索库被污染的情况，设计了一种两阶段的过滤与可信判断方法。**不需要重新训练大模型，可挂在已有 RAG 上：前置用聚类加领域特征过滤可疑文档，后置用一致性比对和四维可靠性评估识别冲突、必要时拒答。该方法能缓解投毒影响，但不能完全防住，高投毒率下尤其乏力。

### 7.3 研究不足

受限于研究时间与资源，本文工作仍存在若干不足之处：

(1) **数据规模仍有局限。**本文构建的军事情报问答数据集规模约 1,276 条，虽已覆盖三类典型样本，但相对于军事情报的实际复杂性而言仍显有限，且对海军作战、太空军事、电子对抗等子领域覆盖不充分；

(2) **实时检索引入额外延迟。**动态检索虽然改善了复杂推理质量，但相比静态 RAG 引入了约 1.8 秒的额外检索与重构开销，在极端时效场景下仍需进一步的工程优化；

(3) **对抗防御范围局限。**本文重点针对文本投毒、提示注入等文本领域的对抗攻击进行了防御设计，尚未涉及图像、传感器数据等多模态对抗，而真实军事情报场景下多模态对抗同样不可忽视；

(4) **评估的真实战场迁移性有待验证。**本文评估主要基于公开数据与脱密合作语料，与真实战场情报场景仍有差距，方法在真实部署中的表现需要后续工程化项目进一步验证。

### 7.4 未来工作展望

在本文工作的基础上，未来可从以下几个方向继续深入：

(1) **多模态军事情报 RAG。**将卫星图像、雷达信号、传感器数据等多模态信息融入检索增强生成框架，通过统一的多模态嵌入空间与跨模态一致性检测机制提升对复杂战场情报的综合理解能力；

(2) **基于多智能体协作的情报问答。**设计专门的检索智能体、推理智能体、批判智能体等多智能体协作框架 [?, ?]，通过角色化分工与协商机制处理更加复杂的情报研判任务；

(3) **面向情报知识演化的持续学习。**研究知识库的实时增量更新机制与模型对新知识的快速吸收机制，确保系统能够持续追踪战场态势变化而不影响已有能力；

(4) **形式化可验证的对抗鲁棒性。**从当前的经验性防御进一步迈向具有形式化保证的鲁棒性设计，例如基于认证防御（certified defense）的方法，为军事关键系统提供数学层面的安全保证；

(5) **人机协同的可解释决策支持。**深化系统在解释性输出、不确定性沟通、反事实问询等方向的能力，使系统从“回答器”演进为“决策伙伴”，更好地服务于辅助指挥决策。

面向军事情报问答的检索增强生成方法研究是一项兼具学术价值与工程意义的工作。希望本文工作能为推动军事人工智能由实验室原型走向实战部署提供有益参考，也希望未来在更广泛的多模态、多智能体、可信赖人工智能方向上取得进一步突破。

## 参考文献

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30: 5998–6008.
- [2] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of NAACL-HLT, 2019: 4171–4186.
- [3] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[J]. Advances in Neural Information Processing Systems, 2020, 33: 1877–1901.
- [4] Touvron H, Lavril T, Izacard G, et al. LLaMA: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.
- [5] Ouyang L, Wu J, Jiang X, et al. Training language models to follow instructions with human feedback[J]. Advances in Neural Information Processing Systems, 2022, 35: 27730–27744.
- [6] Yang A, Li A, Yang B, et al. Qwen3 technical report[J]. arXiv preprint arXiv:2505.09388, 2025.
- [7] Guo D, Yang D, Zhang H, et al. DeepSeek-R1: Incentivizing reasoning capability in LLMs via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.
- [8] Alansari A, Luqman H. Large language models hallucination: A comprehensive survey[J]. arXiv preprint, 2025.
- [9] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-rank adaptation of large language models[C]//International Conference on Learning Representations, 2022.
- [10] Han Z, Gao C, Liu J, et al. Parameter-efficient fine-tuning for large models: A comprehensive survey[J]. arXiv preprint arXiv:2403.14608, 2024.
- [11] Robertson S E, Walker S. On relevance weights with little relevance information[C]//Proceedings of SIGIR, 1997: 16–24.
- [12] Robertson S, Zaragoza H. The probabilistic relevance framework: BM25 and beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333–389.
- [13] Karpukhin V, Oguz B, Min S, et al. Dense passage retrieval for open-domain question answering[C]//EMNLP, 2020: 6769–6781.
- [14] Khattab O, Zaharia M. ColBERT: Efficient and effective passage search via contextualized late interaction over BERT[C]//SIGIR, 2020: 39–48.
- [15] Formal T, Piwowarski B, Clinchant S. SPLADE: Sparse lexical and expansion model for first stage ranking[C]//SIGIR, 2021: 2288–2292.
- [16] Chen J, Xiao S, Zhang P, et al. BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation[J]. arXiv preprint arXiv:2402.03216, 2024.

- 
- [17] Wang L, Yang N, Huang X, et al. Text embeddings by weakly-supervised contrastive pre-training[J]. arXiv preprint arXiv:2212.03533, 2022.
  - [18] Cormack G V, Clarke C L A, Buettcher S. Reciprocal rank fusion outperforms condorcet and individual rank learning methods[C]//SIGIR, 2009: 758–759.
  - [19] Lewis P, Perez E, Piktus A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[J]. Advances in Neural Information Processing Systems, 2020, 33: 9459–9474.
  - [20] Ma X, Gong Y, He P, et al. Query rewriting in retrieval-augmented large language models[C]//EMNLP, 2023: 5303–5315.
  - [21] Gao L, Ma X, Lin J, et al. Precise zero-shot dense retrieval without relevance labels[C]//ACL, 2023: 1762–1777.
  - [22] Jiang Z, Xu F F, Gao L, et al. Active retrieval augmented generation[C]//EMNLP, 2023: 7969–7992.
  - [23] Asai A, Wu Z, Wang Y, et al. Self-RAG: Learning to retrieve, generate, and critique through self-reflection[J]. arXiv preprint arXiv:2310.11511, 2024.
  - [24] Yan S Q, Gu J C, Zhu Y, et al. Corrective retrieval augmented generation[J]. arXiv preprint arXiv:2401.15884, 2024.
  - [25] Trivedi H, Balasubramanian N, Khot T, et al. Interleaving retrieval with chain-of-thought reasoning for knowledge-intensive multi-step questions[C]//ACL, 2023: 10014–10037.
  - [26] Jeong S, Baek J, Cho S, et al. Adaptive-RAG: Learning to adapt retrieval-augmented large language models through question complexity[J]. arXiv preprint arXiv:2403.14403, 2024.
  - [27] Hicks K H. Department of Defense data, analytics, and artificial intelligence adoption strategy[R]. Washington D.C.: U.S. DoD, 2023.
  - [28] Zhu M, Xu Z, Zeng K, et al. CMNEE: A large-scale document-level event extraction dataset based on open-source Chinese military news[J]. arXiv preprint arXiv:2404.12242, 2024.
  - [29] Johnson J, Douze M, Jégou H. Billion-scale similarity search with GPUs[J]. IEEE Transactions on Big Data, 2019, 7(3): 535–547.
  - [30] Malkov Y A, Yashunin D A. Efficient and robust approximate nearest neighbor search using HNSW graphs[J]. IEEE TPAMI, 2020, 42(4): 824–836.
  - [31] Wei J, Wang X, Schuurmans D, et al. Chain-of-thought prompting elicits reasoning in large language models[J]. NeurIPS, 2022, 35: 24824–24837.
  - [32] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing reasoning and acting in language models[C]//ICLR, 2023.

- [33] Xie J, Girshick R, Farhadi A. Unsupervised deep embedding for clustering analysis[C]//ICML, 2016: 478–487.
- [34] Blondel V D, Guillaume J L, Lambiotte R, et al. Fast unfolding of communities in large networks[J]. JSTAT, 2008, 2008(10): P10008.
- [35] Campello R J G B, Moulavi D, Sander J. Density-based clustering based on hierarchical density estimates[C]//PAKDD, 2013: 160–172.
- [36] Manakul P, Liusie A, Gales M J F. SelfCheckGPT: Zero-resource black-box hallucination detection for generative LLMs[C]//EMNLP, 2023: 9004–9017.
- [37] Kadavath S, Conerly T, Askell A, et al. Language models (mostly) know what they know[J]. arXiv preprint arXiv:2207.05221, 2022.
- [38] Zhong Z, Huang T, Wang A, et al. PoisonedRAG: Knowledge poisoning attacks to retrieval-augmented generation of LLMs[J]. arXiv preprint arXiv:2402.07867, 2024.
- [39] Greshake K, Abdelnabi S, Mishra S, et al. Not what you have signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection[C]//AISec, 2023: 79–90.
- [40] Perez F, Ribeiro I. Ignore previous prompt: Attack techniques for language models[J]. arXiv preprint arXiv:2211.09527, 2022.
- [41] Lin S, Hilton J, Evans O. TruthfulQA: Measuring how models mimic human falsehoods[C]//ACL, 2022: 3214–3252.
- [42] Es S, James J, Espinosa-Anke L, et al. RAGAS: Automated evaluation of retrieval augmented generation[C]//EACL Demos, 2024: 150–158.
- [43] Thakur N, Reimers N, Rücklé A, et al. BEIR: A heterogeneous benchmark for zero-shot evaluation of IR models[J]. arXiv preprint arXiv:2104.08663, 2021.
- [44] Yang Z, Qi P, Zhang S, et al. HotpotQA: A dataset for diverse, explainable multi-hop question answering[C]//EMNLP, 2018: 2369–2380.
- [45] Trivedi H, Balasubramanian N, Khot T, et al. MuSiQue: Multihop questions via single-hop question composition[J]. TACL, 2022, 10: 539–554.
- [46] Press O, Zhang M, Min S, et al. Measuring and narrowing the compositionality gap in language models[C]//Findings of EMNLP, 2023: 5687–5711.
- [47] Edge D, Trinh H, Cheng N, et al. From local to global: A graph RAG approach to query-focused summarization[J]. arXiv preprint arXiv:2404.16130, 2024.
- [48] Gao Y, Xiong Y, Gao X, et al. Retrieval-augmented generation for large language models: A survey[J]. arXiv preprint arXiv:2312.10997, 2023.

- [49] Zhao W X, Zhou K, Li J, et al. A survey of large language models[J]. arXiv preprint arXiv:2303.18223, 2023.
- [50] Liu N F, Lin K, Hewitt J, et al. Lost in the middle: How language models use long contexts[J]. TACL, 2024, 12: 157–173.
- [51] Shi F, Chen X, Misra K, et al. Large language models can be easily distracted by irrelevant context[C]//ICML, 2023: 31210–31227.
- [52] Su W, Tang Y, Ai Q, et al. DRAGIN: Dynamic retrieval augmented generation based on the real-time information needs of large language models[C]//ACL, 2024.
- [53] Wang L, Ma C, Feng X, et al. A survey on large language model based autonomous agents[J]. Frontiers of Computer Science, 2024, 18(6): 186345.
- [54] Kingma D P, Ba J. Adam: A method for stochastic optimization[C]//ICLR, 2015.
- [55] Loshchilov I, Hutter F. Decoupled weight decay regularization[C]//ICLR, 2019.
- [56] Reimers N, Gurevych I. Sentence-BERT: Sentence embeddings using siamese BERT-networks[C]//EMNLP, 2019: 3980–3990.
- [57] Su J, Lu Y, Pan S, et al. RoFormer: Enhanced transformer with rotary position embedding[J]. arXiv preprint arXiv:2104.09864, 2021.
- [58] Kwon W, Li Z, Zhuang S, et al. Efficient memory management for large language model serving with PagedAttention[C]//SOSP, 2023.
- [59] Fang F, Bai Y, Ni S, et al. Enhancing noise robustness of retrieval-augmented language models with adaptive adversarial training[J]. arXiv preprint arXiv:2405.20978, 2024.
- [60] Rafailov R, Sharma A, Mitchell E, et al. Direct preference optimization: Your language model is secretly a reward model[J]. NeurIPS, 2023, 36.
- [61] Chen Y, Liu H, Mahdavi M. ConfusedPilot: Confused deputy risks in RAG-based LLMs[J]. arXiv preprint arXiv:2408.04870, 2024.
- [62] Wang H, Tan T, Tan F, et al. HippoRAG: Neurobiologically inspired long-term memory for LLMs[J]. arXiv preprint arXiv:2405.14831, 2024.
- [63] Chung H W, Hou L, Longpre S, et al. Scaling instruction-finetuned language models[J]. arXiv preprint arXiv:2210.11416, 2022.
- [64] Sanh V, Webson A, Raffel C, et al. Multitask prompted training enables zero-shot task generalization[C]//ICLR, 2022.
- [65] Pan S, Luo L, Wang Y, et al. Unifying large language models and knowledge graphs: A roadmap[J]. IEEE TKDE, 2024, 36(7): 3580–3599.

- [66] Yasunaga M, Ren H, Bosselut A, et al. QA-GNN: Reasoning with language models and knowledge graphs for question answering[J]. arXiv preprint arXiv:2104.06378, 2021.
- [67] Khattab O, Santhanam K, Li X L, et al. Demonstrate-search-predict: Composing retrieval and language models[J]. arXiv preprint arXiv:2212.14024, 2022.
- [68] Wallace E, Zhao T, Feng S, et al. Concealed data poisoning attacks on NLP models[C]//NAACL-HLT, 2021: 139–150.
- [69] Izacard G, Caron M, Hosseini L, et al. Unsupervised dense information retrieval with contrastive learning[J]. TMLR, 2022.

## 在学期间取得的学术成果和参加科研情况

### 一、攻读学位期间发表的学术论文

1. 舒 适, 汪彦婷, 刘 康. 基于实时信息需求的动态检索增强生成方法在军事情报问答中的应用研究 (拟投稿) .
2. 舒 适, 刘 康, 汪彦婷. 面向对抗环境的检索增强生成噪声过滤方法研究 (拟投稿) .

### 二、攻读学位期间参与的科研项目

1. 西安翔腾微电子科技有限公司项目 “军事 AI 大模型关键技术研究” (项目主要参与人) .
2. 中国航空研究院 631 所联合研究项目 “面向军事情报领域的检索增强生成关键技术” (项目主要参与人) .

### 三、攻读学位期间获得的发明专利

暂无.

### 四、攻读学位期间所获奖励

暂无.



## 致 谢

三年的研究生学习时光匆匆而过。在毕业论文即将完成之际，谨向所有在学习、研究与生活中给予我帮助与支持的师长、同学、家人致以最诚挚的谢意。

首先，衷心感谢我的校内导师汪彦婷老师。在论文选题、方法设计、实验方案与写作每一个环节，汪老师都给予了悉心指导与无私帮助。汪老师严谨的治学态度、敏锐的学术眼光以及对学生的耐心与关怀，使我在研究方法与学术素养上均获得长足进步，是我治学的榜样。

衷心感谢我的校外导师马城城老师以及西安翔腾微电子科技有限公司的各位领导与同事。在校外实习期间，马老师与各位同事在课题方向选择、工程实践、资源支持等方面给予了大力帮助，使我能够把课题与实际工程需求紧密结合，所学得以学以致用。

感谢西北工业大学软件学院的各位老师在我求学期间传授知识、答疑解惑。各位老师严谨的教学风格与对学生发展的关心使我受益匪浅。

感谢实验室一同奋斗的师兄师姐、同门以及师弟师妹们。三年的朝夕相处，我们在科研讨论、项目协作、日常生活中相互鼓励、共同成长，这段经历是我研究生生涯最珍贵的记忆之一。

感谢我的家人始终如一的理解、鼓励与支持。是他们的默默付出，让我能够心无旁骛地完成学业。

最后，衷心感谢在百忙之中评阅本文的各位专家学者，期待并感谢您提出的宝贵建议。

舒 适  
于西北工业大学  
2027 年 3 月